

Büyük Muhakeme Modelleri (LRM) ve Modern LLM'lerle Kıyaslama

Giriş

2025 itibarıyla yapay zeka alanında odak noktası **Büyük Dil Modelleri (Large Language Models - LLM)** kavramından **Büyük Muhakeme Modelleri (Large Reasoning Models - LRM)** kavramına doğru kaymaya başlamıştır ¹. LRM kısaltması bazen **“Large Reasoner Model”** olarak da geçmektedir ve endüstride büyük ilgi görmektedir ². Peki, LRM nedir ve neden LLM'lerin yerini almaya başlamıştır? Bu raporda LRM'lerin ne olduğunu, nasıl çalıştıklarını, ne işe yaradıklarını detaylı olarak açıklayacak; modern LLM'lerle aralarındaki farkları ve karşılaştırmalı sonuçları ele alacağız. Ayrıca son dönemde tartışılan **“universal approximate retrieval”** kavramının anlamını ve LRM'lerle ilişkisini inceleyeceğiz. Tüm bilgileri güncel (2024-2025) akademik gelişmeler ve saygın makalelere dayandırarak aktaracağız.

LRM Nedir ve Nasıl Çalışır?

Büyük Muhakeme Modelleri (LRM), temel olarak LLM mimarisini (genellikle transformer tabanlı büyük dil modelleri) kullanan ancak eğitim ve çalışma biçimi farklılaştırılarak **mantıksal akıl yürütme yeteneklerini** geliştirmeye odaklanan yeni nesil yapay zeka modelleridir ³. Bir LLM, devasa miktarda metin verisindeki istatistiksel kalıpları öğrenerek insan benzeri akıcı metin üretebilirken, bir LRM bu yeteneği bir adım ileri taşıyarak **girdiği karmaşık problemleri adım adım çözmeye, mantık silsileleri kurmaya** odaklanır ³. Başka bir deyişle LRM, LLM'in dil becerisini bir “temel” olarak alır ve üzerine **tutarlı akıl yürütme mekanizmaları** inşa eder. Böylece LRM, bir sorunu çözerken eğitim verilerindeki çeşitli bilgilerden yararlanıp **çıkartım yaparak** sonuç üretir ve çıktıları gerçek dünya senaryolarıyla daha uyumlu, mantıksal olarak tutarlı hale gelir ⁴. Bu nedenle LRM'ler, özellikle dinamik problem çözme ve nüanslı karar alma gereken alanlarda (ör. tıbbi teşhis, finansal sahtekarlık tespiti gibi) **daha güvenilir** sonuçlar verebilir ⁵.

LRM'lerin çalışma prensibi LLM'lere kıyasla farklı bazı eğitim ve çıkartım tekniklerini içerir. Genel hatlarıyla, bir LRM aşağıdaki yöntemlerle geliştirilir ve çalıştırılır:

- **Zenginleştirilmiş veri setleriyle eğitim:** LRM'ler sadece düz metin örüntülerini değil, aynı zamanda akıl yürütmeyi öğreten örnekleri de içeren özel veri kümeleriyle eğitilir. Örneğin, **gerçek dünya senaryoları** ve bunların açık sonucu/adım-adım çözümü içeren problemler modele gösterilir ⁶. Bu sayede model hem doğru çıktıları hem de o çıktıları ulaştırmak için gerekli mantık adımlarını öğrenir ⁶.
- **Pekiştirmeli öğrenme ve insan geribildirim:** Bazı LRM'ler, önceden eğitilmiş LLM üzerine ek bir **pekiştirmeli öğrenme (Reinforcement Learning, RL)** aşamasından geçirilir. Doğru veya tutarlı mantık içeren cevaplar için model ödüllendirilip yanlışlar için cezalandırılarak, istenen muhakeme kalıpları pekiştirilir ⁷. Ayrıca **insan geri bildirimiyle pekiştirme (RLHF)** de uygulanabilir; insan değerlendiriciler modelin çıktısını yönlendirerek özellikle hassas veya uzmanlık gerektiren alanlarda modelin daha **nüanslı akıl yürütme stratejileri** öğrenmesini sağlar ⁸. Örneğin, sağlık veya finans gibi alanlarda insan uzmanlar modelin karar süreçlerini değerlendirip düzeltmeler yaparak modelin mantık yürütmesini o alandaki gerekliliklere göre hizalar.

• **İstem mühendisliği ve zincirleme düşünce (Chain-of-Thought, CoT) teknikleri:** Model eğitimi sonrasında bile, modelin nasıl komutlandırıldığı (prompt engineering) çıkardığı mantık üzerinde kritik rol oynar ⁹ . Etkili istemler, modele çok adımlı problemleri parçalara bölerek çözmesi gerektiğini telkin edebilir ⁹ . Özellikle **Zincirleme Düşünce** istemleri, modelin sorunu kendi içinde adım adım çözmesini teşvik eden bir yaklaşımdır. Bu yöntemde modele “Parçalara ayırarak düşün” tarzı yönlendirmeler verilerek, bir soruyu yanıtlarken önce alt adımlar üretmesi, kendi kendine ara sorular sorup cevaplaması sağlanır ¹⁰ . Bu sayede model, karmaşık bir soruya doğrudan tek adımda cevap vermek yerine, tıpkı bir insan gibi “**Önce şunu yapalım... sonra bunu hesaplayalım... sonunda cevaba ulaşalım**” şeklinde akıl yürütebilir. Nitekim yapılan araştırmalar, LRM’lerin iç mantık sürecinde “**Hmm...**”, “**Bir dakika...**”, “**Şimdi düşünüyorum...**” gibi düşünme ifadesi taşıyan kelimeler kullandığını ve bu “**düşünce belirteçlerinin**” modelin başarılı çıkarım yapmasında kritik rol oynadığını göstermektedir ¹¹ ¹² . Modelin çıktısından bu tür düşünme ifadelerini çıkarmak, muhakeme performansını belirgin biçimde düşürmektedir ¹² . Bu bulgu, LRM’lerin zincirleme düşünce esnasında adeta iç sesle kendi kendine muhakeme ettiğini ve bunun sonuca ulaşmada önemli olduğunu ortaya koyar.

Yukarıdaki yöntemler sayesinde LRM’ler, standart LLM’lere göre farklı bir **çalışma davranışı** sergiler. Özellikle 2025 itibarıyla ön plana çıkan bir yaklaşım, modelin **çıkartım yaparken daha fazla hesaplama zamanı ve imkânı kullanmasıdır**. LLM’ler genellikle sabit bir hesaplama ile hızlı tahmin yaparken, LRM felsefesinde modele “düşünmesi için daha fazla zaman verme” esastır ¹³ . Bu durum literatürde “**inference-time compute**” artışı olarak adlandırılır ve Satya Nadella gibi sektör liderleri tarafından LRM döneminin ayırt edici özelliği olarak vurgulanmıştır ¹⁴ . Basit bir ifadeyle, LRM bir problemi çözerken *daha uzun süre ve/veya daha fazla adımda işlem yaparak* sonuca varır; böylece bir soruya yanıt vermeden önce pek çok olasılığı değerlendirip en mantıklı cevabı oluşturabilir.

LRM’lerde çıkarım zamanı hesaplamasının artırılması farklı şekillerde uygulanabilir. Güncel derlemelerde bu yaklaşımlar üç ana kategoriye ayrılmıştır ¹⁵ :

1. **Model belleğini güncelleme:** Model, yeni karşılaştığı bir bilgiyi veya veriyi *hemen öğrenip* daha sonraki sorularda kullanmak üzere belleğine alabilir ¹⁶ . Örneğin, LLM’ler eğitildikleri dönemden sonra oluşan güncel bir bilgiyi bilemeyebilir; ancak bir LRM, çalışma zamanında bu yeni bilgiyi sisteme dahil ederek kendini güncelleyebilir. Bu sayede bir **bilgi erişim sistemi** gibi davranarak sonradan öğrendiği bir içeriği gelecekteki yanıtlarda hatırlar hale gelir ¹⁶ .
2. **Arama ve keşif yapma:** Model, zor bir soruya cevap ararken farklı çözüm yollarını deneyip bir arama süreci yürütebilir ¹⁶ . Bu, harici bir arama motoru kullanma şeklinde (internet veya bilgi tabanından arama yapmak gibi) olabileceği gibi, modelin kendi içinde farklı olası çözümleri türetilip değerlendirmesi şeklinde de olabilir. Bu yöntem, modele bir satranç hamlesini hesaplatırken tüm olasılıkları taraması veya bir matematik problemde farklı çözüm yöntemlerini sınaması gibi düşünülebilir. LRM’ler bu şekilde *çok sayıda aday çözüm üretip içlerinden en iyi olanı seçme* yeteneğine sahip olacak biçimde tasarlanmaktadır ¹⁶ .
3. **Aktif öğrenme (test-time training):** Bu yaklaşımda model, karşılaştığı yeni bir problem türünde kendi parametrelerini dahi güncelleyerek (küçük bir yeniden öğrenme adımı yaparak) o problemde uzmanlaşmaya çalışabilir ¹⁷ . Yani, LLM’lerin normalde sabit kalan parametreleri LRM senaryosunda bazı durumlarda *dinamik olarak ayarlanabilir*. Bu elbette zor bir işlemdir ve her durumda uygulanmaz, ancak araştırmalar bazı LRM prototiplerinde modelin çıkarım sırasında mini bir eğitim döngüsü geçirerek becerilerini geliştirmeye çalıştığını göstermektedir ¹⁷ .

Özetle, LRM’ler mimari olarak LLM’lerle büyük ölçüde benzer olsa da (çoğunlukla transformer tabanlı çok büyük ağlar), **eğitim verileri, eğitim teknikleri ve çıkarım stratejileri** bakımından farklılaşarak

daha ileri düzeyde akıl yürütme imkânı sunarlar. Bu nedenle LRM'ler, klasik LLM'lerin zorlandığı çok adımlı mantık, matematiksel akıl yürütme, stratejik planlama gibi konularda daha başarılı olmayı hedefler.

LRM'lerin Kullanım Alanları ve Yetenekleri

LRM'lerin gelişimi, pratikte pek çok önemli uygulama alanında çığır açıcı imkânlar sunmayı amaçlar. Genel olarak, LRM'ler **bilgiye erişim**, **karar destek** ve **karmaşık problem çözme** gerektiren senaryolarda klasik LLM'lere göre daha üstün performans sergiler. İşte bazı önemli kullanım alanları:

- **Bilgiye Erişim ve Soru-Cevap Sistemleri:** LRM'ler, devasa bilgi kaynaklarına erişip sorulan soruya **en doğru cevabı mantıksal süzgeçten geçirerek getirme** konusunda etkilidir. Örneğin, şirket içi belge ve veritabanlarına bağlı bir LRM, kullanıcının sorduğu ayrıntılı bir soruyu ilgili tüm belgeleri tarayıp analiz ederek tutarlı bir yanıt haline getirebilir. Bu, bir bakıma klasik bilgi-alma (retrieval) sistemlerinin LLM yetenekleriyle birleşimi gibidir: LRM, yalnızca ilgili bilgiyi bulmakla kalmaz, aynı zamanda bunu anlamlandırıp soruya uygun şekilde formüle eder. Böyle bir sistem, karmaşık ve çok adımlı soruları yanıtlarken, her adımda mantığını açıklayarak daha **güvenilir ve şeffaf** bir cevap sunabilir.
- **Karar Destek ve Uzman Sistemler:** LRM'ler, tıp, hukuk, finans gibi alanlarda **karar destek sistemleri** olarak kullanılmaya başlanmaktadır. Örneğin, **klirik teşhis** destek sistemlerinde bir LRM, hastanın şikayetleri ve test sonuçları gibi **belirsiz veya eksik verileri** analiz ederek en olası teşhisleri ve bu teşhislere hangi belirtilerin yol açtığını mantıksal bir yaklaşımla çıkarabilir ¹⁸. Bu, **abdüktif (en iyi açıklamayı bulucu) akıl yürütme** yeteneğiyle ilgilidir: LRM, mevcut kanıtlara bakarak olası açıklamalar oluşturur ve bunları olasılıklarına göre sıralar ¹⁹. Benzer şekilde, **finansal sahtekârlık tespiti** alanında LRM'ler, büyük hacimli işlem verilerini tarayıp normal dışı desenleri yakalayarak olası dolandırıcılık vakalarını tespit edebilir ²⁰. Bu görev, çok sayıda veriden **indüktif (genelleme yoluyla) akıl yürütme** gerektirir: LRM, tekil örneklerden yola çıkarak genel bir anomali tanımı oluşturur ve bunu yeni verilere uygular ²¹.
- **Karmaşık Planlama ve Problem Çözme:** LRM'ler, **çok adımlı planlama** gerektiren problemlerde ve zekâ oyunlarında da kullanılmaktadır. Örneğin bir LRM, **satranç** gibi stratejik oyunlarda geleceğe dönük hamleleri hesaplayarak insana yakın veya üstün performans sergileyebilir. Bu, LLM'lerin önceden zorlandığı bir konuydu; ancak LRM'lerin dahili olarak hamleleri ileriye dönük simüle edip değerlendirme yapabilmesi sayesinde bu alanda ilerleme kaydedilmiştir. Yine matematiksel problem çözmede LRM'ler oldukça başarılı sonuçlar vermektedir. Bir matematik sorusunu, teoremleri veya formülleri sırayla uygulayarak çözebilir, gerekirse önceki adımlarda yaptığı çıkarımları kontrol edip hata varsa düzelterek sonuca gidebilir. Bu sayede, özellikle **matematik, mantık bulmacaları, programlama** gibi adım adım düşünme gerektiren alanlarda LRM'ler güçlü birer araç haline gelmektedir.
- **Yaratıcı ve Çok Adımlı İçerik Üretimi:** LLM'ler halihazırda metin üretiminde iyidir, ancak uzun ve tutarlı akış gerektiren durumlarda zaman zaman tutarsızlıklar ortaya çıkabilir. LRM'ler, uzun bir metni planlama ve tutarlı bir yapı içinde üretme konusunda da avantaj sağlayabilir. Örneğin, çok bölümlü bir hikaye ya da rapor yazarken, LRM kendi içinde mantık kuralları ve kronolojik tutarlılık denetimleri yaparak bölümler arası uyumu sağlayabilir. Bu, akıl yürütme yeteneğinin bir yansımasıdır: Model, sadece cümle düzeyinde değil, bütünsel bir mantıkla tutarlı içerik üretmeye çalışır.

Yukarıdaki kullanım alanlarında LRM'lerin başarısı, onların **daha derin anlama ve çıkarım yapabilme** özelliklerinden gelir. Modern LRM'ler, belirsiz ya da eksik veriyle de çalışıp **hipotez oluşturabilir (abdüktif)**, çok sayıda örnekten genelleyip **desen yakalayabilir (indüktif)**, kuralları uygulayıp **kesin sonuçlara varabilir (dedüktif)** ve bildiği benzer durumları **yeni durumlara uygulayabilir (analojik)** ^{22 23}. Bu sayede, LRM'ler gerçek dünyada **daha yüksek riskli ve kritik** görevlerde kullanılmaya başlanmıştır. Örneğin, bir LLM hızlı bir şekilde müşteri destek sorularını yanıtlama gibi düşük riskli işlerde yeterli olabilirken, bir LRM **tıbbi tanı önerme veya finansal planlama** gibi hataya toleransı az ve açıklanabilirliğin önemli olduğu işlerde tercih edilir, çünkü mantığını açıklayarak daha doğrulanabilir cevaplar sunabilir ²⁴.

LRM ve LLM Karşılaştırması: Temel Farklar

Modern LLM'ler ile LRM'ler arasındaki farklar, amaç ve yetenekler açısından belirgin hale gelmektedir. Aşağıda LLM ve LRM'lerin bazı temel boyutlarda karşılaştırması yer almaktadır:

- **Çekirdek İşlev:** LLM'lerin temel görevi, devasa veri kümelerindeki dil kalıplarını öğrenerek **akıcı ve insan benzeri metinler üretmektir**. LRM'ler ise bu dili üretme becerisini genişleterek, **mantıksal akıl yürütme ve bağlamsal anlama gerektiren sorunları çözmeye odaklanır** ²⁵. Yani LLM, görgül bir şekilde "dilini istatistiğini" öğrenir ve akıcı cevap verir; LRM ise "düşünerek cevap verme" kabiliyeti ekler.
- **Kullanım Alanları:** LLM'ler sıklıkla **içerik üretimi, dil çevirisi, özetleme, sohbet botu yanıtları** gibi dilsel akıcılığın ve hızın önemli olduğu görevlerde kullanılır. Buna karşın LRM'ler **matematik problemlerinin çözümü, muğlak bir klinik verinin yorumlanması, karmaşık karar verme süreçleri** gibi mantık zinciri gerektiren durumlar için tercih edilir ²⁶. Örneğin GPT-3 veya GPT-4 gibi LLM'ler bir paragrafı çevirmede veya bir e-postayı taslaklamada çok başarılı iken, bir LRM modele entegre mantık sayesinde bir bulmaca çözmede veya tıbbi bir vaka analizinde daha yetkin olabilir.
- **Mantıksal Akıl Yürütme Yeteneği:** Standart LLM'ler, belirli düzeyde mantık yürütebilse de **çok adımlı muhakeme** veya belirsizlik içeren durumlarda genellikle zorlanırlar. Birden fazla adım gerektiren matematik işlemlerinde hata yapmaları ya da bağlamdan kopmaları bunun örneklerindendir. Buna karşılık LRM'ler, **tutarlı mantık adımlarını uygulayacak şekilde özel olarak eğitilirler**. Sonuç olarak LRM çıktıları daha **mantıklı, tutarlı ve doğrulanabilir** olma eğilimindedir ²⁴. LRM, ara adımları saklı veya açık şekilde takip ederek sonuca gittiği için, her adımın mantığı denetlenebilir. Bu durum, LRM'lerin cevaplarında halüsinasyon (uydurma bilgi) riskini de azaltır çünkü her iddiayı daha iyi temellendirme eğilimindedirler.
- **Performans ve Hız:** LLM'ler genellikle **hızlı yanıt süreleri** sunmak üzere optimize edilmiştir; çok büyük modeller olsa bile tek bir adımda yanıt üretir ve kullanıcı bekletilmez. LRM'ler ise problem çözme esnasında içsel olarak birden fazla adım ürettikleri veya daha uzun zincirleme düşünme süreçleri yürüttükleri için **daha yavaş yanıt verebilirler** ve daha fazla işlemci/güç tüketebilirler ²⁷. Örneğin, bir LRM'nin karmaşık bir soruya yanıt üretirken binlerce "gizli" token üzerinden akıl yürüttüğü ve bu yüzden tek bir cevap için normalden çok daha fazla hesaplama yaptığı kaydedilmiştir ^{28 29}. Bu, LRM kullanımının maliyetini ve gecikmesini arttırabilir. Dolayısıyla LLM'ler **yüksek hacimli, düşük riskli** işler için ideal iken, LRM'ler **düşük hacimli ama yüksek doğruluk kritiği olan** işler için tercih edilir diyebiliriz ³⁰.
- **Açıklanabilirlik ve Doğruluk:** LRM'lerin en büyük avantajlarından biri, gerekirse adım adım akıl yürütme yolunu sunabilmeleri, yani bir nevi **"düşünce izlerini"** göstermeleridir. Bu durum,

özellikle kararların denetlenmesi gereken kurumsal ortamlarda veya uzmanlık isteyen konularda çok değerlidir. Bir LLM ise genellikle cevabı tek seferde verdiği için, bu cevabın nasıl üretildiğini veya hangi bilgilerden yararlandığını görmek zordur. LRM'ler iç mantık adımlarını dışa vurmaya daha yatkın olduğundan, **çıktılarının gerekçelerini açıklayabilir** ve böylece kullanıcının sonuca güven duymasını kolaylaştırır ³¹ ³² .

Yukarıdaki farklar pratik sonuçlarda da kendini göstermiştir. **Karşılaştırmalı değerlendirmeler**, LRM'lerin belirli görevlerde modern LLM'lere kıyasla çarpıcı üstünlükler elde ettiğini ortaya koymaktadır:

- **OpenAI GPT-4 vs LRM (OpenAI O1):** OpenAI, 2024 sonlarına doğru GPT-4 tabanlı ilk büyük muhakeme modeli olan **"o1"** kod adlı LRM'yi tanıttı. Bu model, GPT-4 gibi güçlü bir LLM'in ince ayarlı bir sürümü olup, içsel olarak zincirleme düşünce mekanizmalarıyla donatılmıştı ³³ . Yapılan testler, o1 modelinin GPT-4'ün başaramadığı bazı strateji ve mantık görevlerinde önemli başarı sağladığını gösterdi. Örneğin, GPT-4 (ChatGPT-4) veya benzeri modeller **satranç** gibi çok hamleli strateji oyunlarında pek başarı gösteremezken, o1 modeli rastgele bir satranç programına karşı oyunların yaklaşık %47'sini kazanmayı başardı – bu, önceki LLM'lerin ulaşamadığı bir performanstı ³⁴ . Benzer şekilde, akıl yürütme yeteneğini ölçen ARC-AGI gibi zorlu testlerde o1 yeni bir seviye belirleyerek manşetlere çıktı ³⁵ . Yine matematik, mantık ve kodlama alanlarında, o1 içsel zincirleme akıl yürütme süreci sayesinde GPT-4'ün veya Claude 2/3 gibi modellerin takıldığı sorunları çözebildiği gözlemlendi ³⁴ . Bu başarılar, LRM yaklaşımının salt model ölçeğini büyütmeyle elde edilemeyen bir *niteliksel sıçrama* sağladığını ortaya koymaktadır. Öte yandan, o1'in de kusursuz olmadığı not edilmelidir: Bazı basit görünen sorularda bile "aşırı düşünerek" yanlış cevaba gittiği ya da zincirleme düşünürken aşırı uzun çıktılar ürettiği rapor edilmiştir ³⁶ . Hatta o1, bir soruya gizli binlerce adımlık bir mantık silsilesi oluşturduğu için **çok yavaş ve maliyetli** yanıtlar verebilmektedir ²⁸ . Bu nedenle LRM'nin faydası kadar, verimlilik dezavantajı da pratikte dikkate alınmaktadır.

- **Alibaba Qwen vs LRM (QwQ):** Çin merkezli Alibaba şirketi, açık kaynak camiasına **Qwen** adlı bir LLM serisi sunmuştur (7 milyar, 14 milyar parametrelili versiyonları bulunan güçlü bir model ailesi). 2024 sonu ve 2025 başında Alibaba araştırmacıları, Qwen tabanlı **QwQ** adını verdikleri bir LRM ortaya çıkardılar ³⁷ ³⁸ . **QwQ (Qwen-with-Questions)**, yaklaşık 32 milyar parametrelili bir model olup özellikle matematiksel muhakeme ve mantık sorularında üstün performans için zincirleme düşünme tarzında eğitilmiştir ³⁹ . Bu modelin dikkat çekici yönü, nispeten daha küçük bir veri seti (yaklaşık 17 bin yüksek kaliteli adım-adım çözüm içeren örnek) ile eğitilmesine rağmen, mantık yürütme konusunda **çok daha büyük modelleri bile geride bırakan** sonuçlar elde etmesidir ⁴⁰ ⁴¹ . Özellikle matematik ve programlama problemlerinde QwQ, kendi parametre boyutundan kat kat büyük kapalı modellerle yarışıp onları aşan bir performans sergilemiştir ⁴² . Örneğin, MATH-500 ve AIME (American Invitational Math Exam) gibi zorlayıcı sınav setlerinde **en üst düzey** sonuçlara ulaşarak, devasa LLM'lerle boy ölçüşmeyi başarmıştır ⁴³ . Bu durum, **odaklı ve kaliteli bir mantık eğitiminin** model boyutunu kısmen telafi edebileceğine işaret etmektedir. QwQ'nun başarısı, aynı zamanda açık kaynak dünyasında da LRM yaklaşımının benimsendiğini ve özelleştirilmiş modellerle ileri seviye akıl yürütmenin mümkün olduğunu göstermektedir ⁴⁴ . QwQ, dahili olarak *"kendi kendine soru sorma"* ve *"iç diyalog"* tekniklerini kullanmasıyla bilinir; zor bir problemle karşılaştığında önce kendi kendine alt sorular üretip bunları cevaplayarak ilerlediği rapor edilmiştir ⁴⁵ ⁴⁶ . Bu, LRM'lerin davranışsal olarak da insana benzer şekilde düşünebildiğine bir örnektir.

Yukarıdaki örnekler dışında, Google'ın geliştirdiği **Gemini** modelinin 2. versiyonunda "Flash Thinking" adı verilen açık düşünme modunun entegre edildiği ve OpenAI'nın o1 modeline benzer şekilde inference-time (çıkartım zamanı) mantık yürütme kabiliyetleri sunduğu belirtilmektedir ⁴⁷ . Hatta OpenAI'nın o1 modelini takiben 2025 yılında duyurduğu **o3** modelinin, çok daha uzun mantık zincirlerini

kaldırabilen, devasa bir bağlam penceresiyle (200 bini aşan token bağlam uzunluğu) çalışabilen ve son derece zor bilimsel sınavlarda ~%88 başarıyla yeni rekorlar kırdığı rapor edilmiştir ⁴⁸ ⁴⁹ . Örneğin, yüksek seviyeli bir bilim sınavı olan GPQA'da o3 modeli %87.7 puan alarak tipik LLM'lerin çok üzerinde bir performans sergilemiştir ⁵⁰ . Bu gelişmeler, LRM yaklaşımının sadece tekil örneklerle sınırlı kalmadığını, büyük oyuncular tarafından da yeni standart olarak benimsendiğini göstermektedir.

Universal Approximate Retrieval Kavramı ve LRM'lerdeki Rolü

Universal approximate retrieval terimi, LLM'lerin yeteneklerini eleştirel bir bakışla tanımlamak için ortaya atılmış bir kavramdır. Türkçeye kabaca “evrensel yaklaşık getirim” ya da “tahmini evrensel hatırlama” olarak çevrilebilir. Bu ifade, büyük dil modellerinin aslında gerçek anlamda mantık yürütmedikleri; onun yerine eğitim verilerindeki bilgileri bir şekilde **genelleştirerek geri çağırdıkları** fikrini vurgular ⁵¹ . Arizona State University'den Prof. Subbarao Kambhampati'nin 2024 tarihli bir makalesinde belirttiği gibi, LLM'ler özünde “n-gram modelinin steroid almış hali” olarak görülüp, kelime dizilerini tam eşleşmeyle değil ama olasılıksal olarak **tamamladıkları** için devasa bir **doğrusal olmayan hafıza** gibi davranırlar ⁵² ⁵³ . Bu bakış açısına göre, LLM'ler bir veritabanı gibi **tam ezberden getirme** yapmaz; bunun yerine sorguya uygun görünen parçaları **tahmini olarak bir araya getirir** ⁵³ . Bu nedenle LLM yanıtları bazen yaratıcı ve yeni görünür (çünkü birebir kopyalama yapmaz, parçaları karıştırıp üretir) ancak bazen de gerçeklikten kopuk “uydurma” bilgiler içerir – ki bu durum, modelin aslında tam olarak neyi hatırlayıp neyi uydurduğunu bilememesinden kaynaklanır ⁵⁴ . **“Hallusinasyon”** dediğimiz olgu da aslında bu evrensel yaklaşık getirim sürecinin bir yan ürünüdür: Model, soruya benzer gördüğü eğitim örneklerini birleştirirken, gerçekte var olmayan detaylar uydurabilir.

Bu kavramın LRM'lerle ilişkisine gelince: LRM'ler, LLM'lerin **“approximate retrieval”** davranışını tamamen ortadan kaldırmasa da, onun yol açtığı sınırlamaları aşmayı hedefler. Kambhampati ve ekibinin yaptığı deneyler, LLM'lerin bir görevi gerçekten mantık yürüterek mi yoksa sadece bildiklerine benzer görünen cevapları hatırlayarak mı yaptığını ayırt etmeye çalışmıştır. Örneğin, bir planlama probleminde (blok dünyası gibi) eylemlerin ve nesnelerin isimleri anlamsız şekilde değiştirildiğinde (obfuscation), GPT-4 gibi güçlü bir modelin performansının **ani ve ciddi biçimde düştüğü** rapor edilmiştir ⁵⁵ . Oysa aynı problem, klasik arama tabanlı planlama algoritmaları için isimlerin ne olduğundan bağımsız olarak çözülmeye devam edilebilirdi. GPT-4'ün sadece yüzeyde tanıdığı kalıplar bozulduğu için başarısız olması, onun aslında problemi insan gibi mantıkla çözmediğini, büyük ölçüde **eğitim verisinden yaklaşık bir hatırlama yaptığını** göstermektedir ⁵⁵ . İşte LRM yaklaşımı tam bu noktada devreye girer.

LRM'ler, LLM'lerin “approximate retrieval” özelliğini daha kontrollü ve entegre bir şekilde kullanmayı ya da onun ötesine geçmeyi amaçlar. Bir LRM, elbette LLM'in devasa bilgi birikiminden faydalanır – bu bilgi birikimi modelin evrensel (her konuda bir şeyler bilen) yönüdür. Ancak LRM, salt bir “hatırlama makinesi” olmaktan çıkıp **bir analiz ve doğrulama makinesine** evrilir. Bunu sağlamak için LRM'ler çoğu zaman **harici bilgi getirme mekanizmaları** ve **iç mantık denetimleri** kullanır. Örneğin, bir LRM'ye güncel bir soru sorulduğunda, model yalnızca eğitiminde gördüklerini anımsamakla kalmaz; aynı zamanda gerekirse **harici bir bilgi kaynağında arama yapıp** taze bilgi bulabilir, sonra bu bilgiyi kendi cevabına entegre eder. Bu, LRM mimarisine bir **retrieval modülü** eklemekle mümkün olabilir. Nitekim LRM araştırmalarında, modelin çıkarım sırasında bir bilgi bankasına danışması veya internet araması yapması gibi yöntemler üzerinde durulmaktadır ¹⁶ . Bu sayede LRM, LLM'in “yalnızca bildiğini bilmesi” sınırlamasını aşarak **bilmediği şeyi öğrenebilir hale** gelmektedir ⁵⁶ ¹⁶ . Örneğin, bir LLM 2021 sonrası dünya olaylarını bilemezken, LRM yaklaşımıyla donatılmış bir sistem 2025 yılındaki bir haberi sorgu anında bulup cevapta kullanabilir.

Ayrıca LRM'ler, LLM'lerin yaklaşık hatırlama ile getirdiği bilgilere **iç mantık süzgeci** uygulayarak yanlış veya tutarsız kısımları ayıklamaya çalışır. Bu, zincirleme düşünce ve öz-denetim teknikleriyle gerçekleştirilir. LRM, bir yanıtı üretirken kendi ürettiği ara adımları da kontrol edebilir, hatta gerektiğinde “Bir dakika, doğru mu yaptım?” diyerek önceki adımını sorgulayıp düzeltebilir ⁵⁷. Böyle bir **içsel tutarlılık denetimi**, LLM'lerin tipik olarak yapmadığı ancak LRM'lerin benimsediği bir strategidir. Örneğin, QwQ gibi modellerin eğitiminde, modele ilk cevabına güvenmemesi, kendiyi çelişip çelişmediğini kontrol etmesi yönünde talimatlar verilmiş ve bunun matematik performansını önemli ölçüde artırdığı gözlemlenmiştir ⁵⁸.

Sonuç olarak *universal approximate retrieval*, LLM'lerin güçlü ama ham hali olarak görülebilir; LRM'ler ise bu ham gücü işleyip cıralayarak **daha tutarlı, doğrulanabilir ve gerektiğinde dış dünyayla entegre** cevaplar üretir hale gelir. LRM yaklaşımı, LLM'lerin yaklaşık anımsama yeteneğini tamamen reddetmez, tam tersine onun üzerine inşa edilir: Geniş bir bilgi uzayından esnek şekilde ilgili verileri çekebilme becerisi, uygun mantık kalıplarıyla birleştğinde LRM'yi hem **geniş bilgi kapsamına sahip** hem de **derin muhakeme yeteneği olan** bir sistem yapar. Bu sayede LRM'ler, bilgiye erişim, karar destek ve karmaşık problem çözme görevlerinde yeni bir dönemi başlatmış durumdadır.

Sonuç

Büyük Muhakeme Modelleri (LRM'ler), günümüz yapay zeka araştırmalarının LLM sonrası evrimini temsil etmektedir. LRM'ler, devasa dil modellerinin dil üretme becerisini güçlü mantık yürütme yetenekleri ile birleştirerek, yapay zeka sistemlerini **daha akıllı, güvenilir ve görev-odaklı** hale getirmektedir. 2025 itibarıyla hem akademik çevrelerde hem de endüstride LRM'lere yönelik yoğun bir ilgi ve hızlı bir gelişim gözlenmektedir ⁵⁹. LRM'ler bilgiye dayalı sistemler, tıbbi/finansal danışmanlar, ileri seviye chatbotlar ve otonom ajanlar gibi pek çok alanda devreye girmeye başlamıştır. Elbette LRM yaklaşımı henüz nihai çözüm değildir; hesaplama maliyeti, verimlilik ve gerçek “anlama” noktasındaki sınırlamalar tartışılmaya devam etmektedir. Ancak açık olan şudur ki, LLM'lerin **“evrensel yaklaşık hatırlama”** kabiliyeti ile yetinmek yerine, ona mantık ve arama yetenekleri aşlamak yapay zekâyı bir sonraki seviyeye taşımaktadır.

Gelecekte LRM konseptinin daha da gelişerek **Büyük Ajans Modelleri (Large Agent Models - LAM)** gibi kendi kendine eylem alabilen sistemlere evrilmesi beklenmektedir ⁶⁰. Bu doğrultuda, güncel araştırmalar hem model mimarilerini hem de eğitim/çıkartım tekniklerini yenileyerek, yapay zekânın sınırlarını zorlamaya devam ediyor. LRM'lerin sunduğu derin muhakeme gücü, bizlere karmaşık problemleri çözebilen, mantığını açıklayabilen ve yeni bilgilere uyum sağlayabilen daha gelişmiş yapay zeka sistemleri vad ediyor. Bu raporda aktarılan güncel akademik bulgular da gösteriyor ki, LRM yaklaşımı yapay zeka alanında **dilsel yeteneklerden bilişsel yeteneklere** geçişin habercisidir.

Kaynaklar: Güncel akademik makaleler ve güvenilir kaynaklar rapor boyunca ilgili yerlerde numaralandırılmıştır. Belirtilen referanslar, LRM ve LLM konusundaki en yeni gelişmeleri ve karşılaştırmaları içermektedir. Bu kaynaklar aracılığıyla okuyucular, tartışılan kavramların dayandığı özgün çalışmalara erişip daha derinlemesine inceleme yapabilirler.

1 2 13 14 15 16 17 56 59 Forget LLMs. LRMs Are All The Rage Now
<https://thewhitebox.beehiiv.com/p/forget-llms-lrms-are-all-the-rage-now>

3 4 5 6 7 8 9 10 18 19 20 21 22 23 24 25 26 27 30 31 32 What are Large Reasoning Models (LRMs)? | AI21
<https://www.ai21.com/glossary/large-reasoning-models/>

11 12 57 Demystifying Reasoning Dynamics with Mutual Information: Thinking Tokens are Information Peaks in LLM Reasoning

<https://arxiv.org/html/2506.02867v1>

28 29 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 58 Comparison of Large Reasoning Models (LRMs) | by Carlos E. Perez | Intuition Machine | Medium

<https://medium.com/intuitionmachine/comparison-of-large-reasoning-models-lrms-dbc468d10906>

51 52 53 54 55 Can Large Language Models Reason and Plan?

<https://arxiv.org/html/2403.04121v2>

60 The path from Large Language Model (LLM) to Large Reasoning...

https://www.researchgate.net/figure/The-path-from-Large-Language-Model-LLM-to-Large-Reasoning-Model-LRM-and-the_fig1_389714108