

Hibrit Yapay Zeka Modelleri: Yeni Gelişmeler ve Uygulamalar (2024-2025)

Hibrit yapay zeka (YZ) modelleri, farklı yapay zeka yöntemlerini (örn. kural tabanlı sembolik akıl yürütme ve derin öğrenme) birleştirerek her birinin güçlü yanlarını tek bir sistemde bütünlüğe hedefler ¹ ². Bu sayede tek bir yönteme dayalı sistemlerin ulaşamadığı esneklik, doğruluk ve yorumlanabilirlik seviyelerine ulaşmak mümkün hale gelir ³ ⁴. Son yıllarda, özellikle **2024 sonrasında itibaren**, hibrit YZ alanında önemli gelişmeler ve akademik çalışmalar yayınlanmıştır. Aşağıda, yeni hibrit model türleri, bunların karar destek ve bilimsel modelleme alanlarındaki kullanımları, teknik mimarileri ve uygulama örnekleri özetlenmiştir.

Yeni Nesil Hibrit Yapay Zeka Türleri

Güncel hibrit YZ araştırmaları, çeşitli AI yaklaşımlarının yenilikçi biçimlerde bir araya getirilmesine odaklanmaktadır. Öne çıkan **yeni ve gelişmiş hibrit model türleri** şunlardır:

- **Nöro-Simgeci Entegrasyon (Neuro-Symbolic AI):** Derin öğrenmenin örüntü tanıma gücünü sembolik AI'ın mantık yürütme ve bilgi temsil yetenekleriyle birleştirir ⁵. Bu sayede hibrit sistemler, hem **veriye dayalı öğrenme** hem de **kural tabanlı çıkarım** yapabilir. Örneğin, IBM'in Neuro-Symbolic Concept Learner (NSCL) modeli görseller üzerindeki soruları cevaplamak için sinir ağlarını algısal yüz, mantıksal kuralları ise çıkarım motoru olarak kullanmıştır ⁶. Nöro-simgeci yaklaşım, son yıllarda hızlı bir büyümeye göstermiştir ve 2020-2023 arasında bu alanda yayınlanan çalışma sayısı katlanarak artmıştır ⁷ ⁸. Araştırmalar, mantık kurallarını sınırlara entegre ederek **ortak akıl çıkarımı**, *daha az veriyle öğrenme* ve *genelleme* yeteneğini geliştirmeyi başarmıştır ⁹ ¹⁰. Örneğin, Plan-SOFAI ve ZeroC mimarileri, nöro-simgeci yöntemlerle planlama ve sıfır atışta kavram tanıma problemlerini çözerek "hızlı ve yavaş düşünme" modellerini entegre etmiş, böylece yapay zekâ planlamasında genel başarıyı artırmıştır ¹¹. Yine benzer şekilde, sinir ağlarının eğitimi *mantıksal kısıtlar* eklenerek model çıktılarının daha tutarlı ve güvenilir olması sağlanmaktadır. Bu amaçla geliştirilen **diferansiyellenebilir mantık katmanları** sayesinde ağlar mantık kurallarını ihlal etmemeyi öğrenebilmektedir (ör. *Pseudo-Semantic Loss* ile model eğitiminde mantıksal ceza terimleri kullanmak, veya **Logic Tensor Networks** ile ağların mantıksal tutarlığını artırmak) ¹². Bu tür yöntemlerle, metin üretiminde olgusal tutarlılığı artırmak veya toksik çıktıları azaltmak mümkün olmuştur ¹². Nöro-simgeci hibritler, özellikle **açıklanabilirlik** ve **güvenilirlik** gerektiren alanlarda öne çıkmaktadır; zira sembolik bileşen, kararların "nedennini" izah edebilir.
- **Bilgi Grafikleri ve Derin Öğrenme Entegrasyonu:** Bu yaklaşım, büyük dil modelleri veya derin ağlara **yapısal bilgi** aşılamayı hedefler. Derin sinir ağları büyük veri içinde örüntü yakalamada iyiyken, **bilgi grafikleri** kavramlar arasındaki ilişkileri ve bağlamı temsil ederek çıkarım yapabilir ¹³ ¹⁴. Hibrit bir modelde sinir ağı, ham verilerden özellikler çıkarırken bilgi grafiği bu özellikleri anlamlandırarak **bağlamsal ve mantıksal tutarlılık** sağlar. Örneğin, doğal dil soru-cevap sistemlerinde neural ağlar metni işlerken, arka planda bir bilgi grafiği ilgili kavramları ve ilişkilerini getirerek sorulara daha tutarlı cevaplar üretmesine yardımcı olabilir ¹⁴. Bu sayede karmaşık çok adımlı çıkarım gerektiren problemler hibrit yaklaşımla çözülmekte ve karar verme iyileşmektedir ¹⁴. Nitekim, bir modelin hem metin embed'leriyle işleyip hem de bilgi grafiğinden çıkarım yaparak zorlu sorgularda başarılı olduğu gösterilmiştir. Son çalışmalar, büyük

dil modellerinin bilgi grafikleriyle birlikte eğitilmesinin tıbbi karar verme gibi karmaşık alanlarda umut vaat ettiğini bildirmektedir; bilgi grafikleri, hastalıklar ve semptomlar arasındaki ilişkileri temsil ederek dil modelinin bu alandaki akıl yürütme kabiliyetini artırabilir ¹⁵ ¹⁶.

- **Fiziksel Model + Makine Öğrenimi Hibritleri:** *Bilimsel modelleme* alanında, **physics-informed** yaklaşımalar olarak da bilinen bu hibrit modeller, fiziksel süreçleri tanımlayan diferansiyel denklemler veya simülasyon modelleri ile veri odaklı öğrenmeyi entegre eder. Amaç, fizik yasalarının sağladığı doğruluk ve tutarlılığı, makine öğreniminin esnekliği ve hesaplama verimliliği ile bir araya getirmektir ¹⁷. Örneğin, iklim biliminde geleneksel simülasyonlar yüksek doğruluk sunar ancak hesaplaması yavaştır; saf derin öğrenme ise hızlıdır fakat fiziksel tutarlılık ve uzun vadeli kararlılık sorunları vardır ¹⁸ ¹⁷. **Hibrit iklim modelleri** bu ikilemi aşmak için geliştirilmektedir: Derin jeneratif modeller kullanarak fiziksel olarak tutarlı okyanus durumu örnekleri üretmek ve bunları iklim projeksiyonlarına başlangıç koşulu yapmak, böylece simülasyonların daha hızlı fakat halen fizik kurallarına uygun şekilde başlatılması sağlanmıştır ¹⁷. Bu "iki dünyanın en iyisi" yaklaşımı, derin öğrenmenin hesaplama verimliliğini sayısal modellerin fiziksel doğruluğu ile birleştirerek iklim değişkenlerini daha etkin modellemeyi mümkün kılmıştır ¹⁷. Benzer şekilde, elektrik şebekesi tahmininde bir sinir ağını **diferansiyellenebilir bir optimizasyon çözümüsü** ile bir araya getiren model, fiziksel kısıtları (ör. güç akışı denklemleri) doğrudan öğrenme sürecine dahil ederek kestirim doğruluğunu artırmış ve görülmemiş ağ topolojilerine genelleşmeyi başarmıştır ¹⁹. **Hidrolojik modelleme** alanında ise, yakın tarihli bir çalışma geleneksel süreci (ör. yağış-akış modelini) tamamlama amacıyla bir sinir ağını modelin içine gömerek karma bir yapı önermiştir ²⁰. Bu hibrit yaklaşımı, fizik tabanlı modelin eksik kaldığı noktalar veriyle öğrenilen bir ağ tarafından telafi edilmiş; sonuça sel tahminlerinde hem uzaysal hem zamansal doğruluk klasik yönteme kıyasla belirgin şekilde artmıştır ²¹. Üstelik, hibrit modelin iç parametrelerinin incelenmesi, modelin farklı havzalardaki hidrolojik davranışlara uyum sağladığını ve bu sayede alttaki fiziksel süreçlere dair içgörü kazandırabileceğini göstermiştir ²¹. Bu tür hibrit "bilgi güdümlü" öğrenme yaklaşımı, bilim ve mühendislik alanlarında, mevcut bilgi birikimini (bilimsel yasalar, mekanistik modeller) ve veri kaynaklarını birlikte kullanarak daha güvenilir ve açıklanabilir yapay zeka modelleri oluşturma eğilimini temsil etmektedir.
- **Kural Tabanlı ve Veri Tabanlı Öğrenmenin Bütünleşmesi:** Bir diğer hibrit yöntem grubu, **uzman sistemlerin** veya insan uzmanlığının getirdiği kural ve mantıkları, makine öğreniminin istatistiksel gücüyle birleştirir. Bu kapsamda **bulanık mantık ile sinir ağlarını** harmanlayan **nöro-bulanık sistemler** uzun süredir kullanılmıştır, ancak derin öğrenme ile yeniden ivme kazanmıştır. Örneğin, 2024 yılında önerilen *DCNFIS (Deep Convolutional Neuro-Fuzzy Inference System)* mimarisi, derin bir evrişimsel sinir ağına bulanık çıkarım katmanı ekleyerek tasarlanmıştır. Bu model, saf derin ağlar kadar yüksek doğruluk elde ederken, bulanık kurallar sayesinde şeffaflığı korumuştur ²². Dört farklı derin sinir aıyla beş veri kümesinde kıyaslandığında en az onlar kadar başarılı olduğu, hatta diğer derin bulanık sistemleri geride bıraktığı gösterilmiştir ²². Nöro-bulanık yaklaşım, insan uzmanlığını temsil eden bulanık kuralların parametrelerini öğrenilebilir hale getirerek belirsizliği yönetmede ve sonuçları açıklamada avantaj sağlar. Benzer şekilde, **evrimsel algoritmalar ile sinir ağlarını** birleştiren hibritler de (ör. evrimsel yöntemle ağ mimarisi veya ağırlıklarının optimize edilmesi) model performansını artırmak için kullanılmaktadır. Özette, önceden ayrı düşünülen AI paradigmalarını (kuralcı vs. öğrenen) bütünlüğetiren hibrit yaklaşım, günümüzde **daha yüksek doğruluk, daha az veri ihtiyacı ve açıklanabilirlik** gibi kazanımlar elde etmek amacıyla çeşitlenerek gelişmektedir ²³ ²⁴. Yapay zekâının genel doğruluğunu tek bir yöntemle daha fazla yükseltmek zorlaştıkça, insan bilişine benzer şekilde **birden fazla düşünme biçimini bir arada kullanan** hibrit sistemlere ilgi artmaktadır ²⁵ ²⁶.

Karar Destek Sistemlerinde Hibrit YZ'nin Rolü

Karar-destek sistemleri, tıp, finans, üretim gibi alanlarda kritik kararların alınmasına yardımcı olmak için tasarlanan yazılımlardır. Bu sistemlerde, **doğruluk kadar kararın gerekçesinin anlaşılabilir olması** da son derece önemlidir. Hibrit yapay zeka modelleri, tam da bu noktada büyük avantaj sunar: Hem veriden öğrenip yüksek doğruluk sağlayabilir, hem de içine gömülü sembolik bilgiler sayesinde kararların mantığını açıklayabilir ²⁷.

Son çalışmalar, hibrit modellerin **karar verme doğruluğunu** tek başına salt sembolik veya salt öğrenen modellere kıyasla belirgin biçimde artırdığını göstermiştir ²⁷. Örneğin, bir kural tabanlı sistem ile derin öğrenmenin birleşimi, yapılandırılmış (tablo verileri gibi) ve yapılandırılmamış (görüntü, metin) veriyi birlikte işleyerek daha güvenilir sonuçlar üretmiştir ²⁷. Dahası, bu birleşim **yorumlanabilirliği** de geliştirmiştir: Sembolik bileşen, nihai sonucun hangi kural veya olgu nedeniyle ortaya çıktığını insan diline yakın şekilde izah edebilmiştir ²⁸. Böylece, uzmanlar veya karar vericiler için "bu karar neden alındı?" sorusu cevapsız kalmamaktadır.

Bu kazanımlar özellikle **sağlık ve finans** gibi kritik alanlarda değerlidir. Örneğin sağlıkta, bir teşhis destek sistemi derin öğrenme ile tıbbi görüntüleri veya hasta verilerini analiz ederken, aynı anda tıbbi kılavuzlardaki kural ve ilişkilere (semantik bilgi) uyar; sonuçta hem hastaya özel bir öneri sunar hem de bunu hangi klinik kılavuza dayanarak yaptığını belirtebilir ¹⁵ ²⁹. Gerçekten de hibrit bir tanı sistemi, görüntü işleme için eğitilmiş bir makine öğrenmesi modelini kullanıp, ardından **semantik bir akıl yürütme** modülüyle elde ettiği bulguları tıbbi protokoller ışığında değerlendirerek hekimlere **daha isabetli ve açıklamalı teşhis önerileri** sunabilir ¹⁶. Bu yaklaşım, yalnızca saf derin öğrenmeye dayalı "kara-kutu" sistemlere kıyasla hekimlerin daha fazla güven duyabileceği, gereklendirilmiş çıktılar üretir.

Benzer şekilde finans alanında, hibrit AI sistemleri **dolandırıcılık tespiti** veya **risk analizi** için kullanılmaktadır. Örneğin bir banka, makine öğrenmesi ile anormal işlem paternlerini yakalarken, eşzamanlı olarak **kural-tabanlı bir denetim modülü** ile yasal mevzuata uyumu kontrol eden bir hibrit model geliştirebilir. Nitekim, 2024'de bildirilen bir yöntem, finansal işlemlerde hibrit model kullanarak hem **şüpheli örüntüler** tespit etmeyi, hem de **düzenleyici kurallara uygunluk** denetimini birlikte gerçekleştirmiştir ³⁰. Bu sayede, tespit edilen olası sahtekârlık vakası için "bu işlemi şu nedenle şüpheli bulduk ve şu kuralı ihlal ediyor olabilir" şeklinde açıklama üretmek mümkün olmaktadır.

Üretim ve operasyonel karar destek sistemlerinde de hibrit yaklaşımlar öne çıkmaktadır. Örneğin akıllı üretim hatlarında, sensör verilerini yorumlamak için makine öğrenmesi kullanılırken, işletme kuralları ve insan uzman bilgisini temsil eden semantik bir sistemle entegre edilmiş hibrit karar destek araçları geliştirilmiştir ³¹ ³². Bu tür sistemler, beklenmedik durumlarda yalnızca veri istatistiğine göre değil, önceden tanımlı iş kurallarına göre de hareket ederek daha **öngörülebilir ve güvenli** kararlar verebilir.

Araştırma topluluğu, **açıklanabilir yapay zeka (XAI)** ihtiyacını karşılamak üzere hibrit modelleri sıkılıkla önermektedir. Çünkü hibritlik, açıklanabilirlik-başarım arasındaki dengeyi iyileştirir: Sembolik bileşenler şeffaflık sağlarken, öğrenen bileşenler yüksek performansı korur ³³ ²². Hatta bazı hibrit sistemler, açıklamaları otomatik türetebilecek şekilde tasarlanmaktadır. Örneğin nöro-bulanık bir modelin ürettiği bulanık kurallar, insan tarafından okunabilir "Eğer X ve Y yüksek ise, risk yüksektir" gibi ifadelerle sistem kararlarını izah etmeye kullanılmıştır ³⁴.

Özetle, hibrit yapay zeka modelleri **karar destek sistemlerinde** iki temel fayda sağlar: (1) **Daha yüksek doğruluk ve adaptasyon** – zira hem kural temelli uzmanlık hem de veriden öğrenme aynı anda kullanılır ³⁵ ¹⁵ – ve (2) **Daha fazla güvenilirlik ve açıklanabilirlik** – zira sonuçlar insan mantığına

uygun açıklamalarla desteklenir³⁶. Bu özellikler, insan uzmanlar ve yapay zeka arasında etkili bir işbirliği kurulmasını kolaylaştırır. Nitekim hibrit zekâ, insan ve AI'nın birlikte karar verdiği "**hybrid intelligence**" yaklaşımının da temelini oluşturarak, karma ekiplerde AI'nın **şeffaf bir takım arkadaşı** gibi davranışmasına imkân tanır³⁷. Sonuç olarak, kritik karar destek ortamlarında hibrit YZ, hem karar kalitesini yükselten hem de kullanıcı güvenini artıran bir çözüm olarak giderek yaygınlaşmaktadır.

Bilimsel Modellemede Hibrit YZ Uygulamaları

Bilimsel araştırma ve mühendislik alanlarında, yapay zeka modellerinin **fiziksel gerçeklerle uyumlu ve güvenilir** olması büyük önem taşır. Saf makine öğrenimi modelleri genellikle kara-kutu niteliğinde olup, fiziksel yasalara aykırı veya anlamsız sonuçlar üretебilir. Bu nedenle son dönemde **hibrit modelleme** yaklaşımları, bilimsel problemleri çözmek için revalatadır. Hibrit bilimsel modeller, **bir yanda fiziksel/kuramsal modelleri veya kuralları**, diğer yanda veriyle öğrenen bileşenleri bir araya getirir.

Özellikle **iklim, enerji, hidroloji, malzeme bilimi** gibi alanlarda hibrit yaklaşımın başarılı örnekleri görülmektedir. Örneğin, **hidroloji** alanında 2025 yılında sunulan bir hibrit model, klasik bir yağış-akış simülasyonunu derin öğrenme ile birleştirmiştir²⁰. Bu çalışmada araştırmacılar, süreç-temelli hidrolojik modelin içерisine *diferansiyellenebilir* bir sinir ağı entegre etmiş, böylece modelin bilinmeyen veya yetersiz temsil edilen fiziksel süreçlerini öğrenerek düzeltmeler yapmasını sağlamıştır³⁸. Sonuçlar, bu hibrit modelin hem **uzayda** (farklı nehir havzalarında) hem de **zamanda** (farklı dönemlerde) saf fiziksel modele kıyasla daha yüksek doğruluk ve dayanıklılık sergilediğini göstermiştir²¹. Önemli, modelin iç parametreleri incelendiğinde, klasik modelin açıklayamadığı bazı akış kalıplarını sinir ağıının telafi ettiği ve böylece hibrit modelin yeni fiziksel içgörüler sunabildiği gözlemlenmiştir²¹. Bu, hibrit yaklaşımın sadece tahmin yapmakla kalmayıp, bilim insanlarına sistemi daha iyi anlama fırsatı verdiği gösterir.

İklim ve hava tahmini alanında da hibrit yöntemlerin yükselişi söz konusudur. **Physics-Informed Neural Networks (PINNs)** adı verilen ve fiziksel denklemleri kayıp fonksiyonuna dahil eden derin öğrenme modelleri, akışkanlar dinamiği veya atmosfer modellemesi gibi zor problemleri çözmede kullanılmaktadır³⁹. 2024 NeurIPS konferansında sunulan bir çalışma, kuantum hesaplama ile PINN'leri bir araya getirerek iklim modellemede hem doğruluğu artırmayı hem de hesaplama maliyetini düşürmeyi başarmıştır⁴⁰ ⁴¹. Bu hibrit yaklaşım, Navier-Stokes denklemleriyle tanımlanan akışkan sistemlerinde, kuantum destekli bir dikkat mekanizması kullanarak benzer doğrulukta sonuçları çok daha az parametre ile elde etmiş ve **daha sürdürülebilir** bir yapay zeka çözümü ortaya koymuştur⁴⁰ ⁴². Yine iklim alanında, klasik modellerde belirsizliği yüksek olan alt ölçekli süreçlerin temsiliini iyileştirmek için **pekiştirmeli öğrenme** hibritleri denemektedir. Bir çalışma, idealize edilmiş iklim modellerine RL algoritmalarını entegre ederek, atmosferdeki zayıf parametrize edilmiş süreçleri doğrudan etkileşim yoluyla öğrenen bir sistem önermiştir⁴³. Sonuçlar, farklı RL yaklaşımının iklim modellerinde belirli senaryolarda geleneksel yöntemlerden daha başarılı olabileceğini ve bu yolla uzun vadede küresel iklim modellerine entegre edilebilecek **öğrenen parametreleştirme şemaları** geliştirilebileceğini göstermiştir⁴³ ⁴⁴.

Malzeme bilimi ve hesaplamalı biyoloji gibi alanlarda da hibrit modeller öne çıkmaktadır. Örneğin bir moleküler simülasyon ile derin öğrenmeyi birleştiren hibritler, kuantum kimya hesaplarını hızlandırırken doğruluk kaybını en aza indirgeyeilmektedir. Benzer şekilde, sayısal optimizasyon problemlerinde **öğrenen kestirimler** kullanmak, büyük ölçekli kombinatoryal problemleri çözmede yeni ufuklar açmaktadır.

Tüm bu örnekler, **bilimsel modellemede hibrit yaklaşımının** ortak bir temasını göstermektedir: **Bilgiye dayalı modelleme ile veri odaklı modelleme** arasındaki uçurumu kapatmak²⁰. Böylece, ne salt fiziksel modelin katılığına ne de salt veriye dayalı modelin belirsizliğine mahkûm olmadan, ikisinin

avantajlarını harmanlayan çözümler elde edilir¹⁷. Sonuç olarak, hibrit YZ modelleri bilimsel araştırmalarda **hesaplama verimliliği, tutarlılık, doğruluk ve yorumlanabilirlik** konularında yeni bir denge sunmaktır; bu da araştırmacılara daha güvenilir simülasyonlar ve daha derin içgörüler sağlar.

Teknik Mimariler ve Örnek Hibrit Sistemler

Hibrit YZ modellerini başarıya ulaştıran en kritik unsur, doğru **mimari tasarım** ve bileşen entegrasyonudur. Literatürde farklı hibrit mimari desenleri geliştirilmiştir. Önemli teknik mimari yaklaşımları ve bunlara ait uygulama örneklerini şöyle özetleyebiliriz:

- **Modüler Nöral-Sembolik Sistemler:** Bu mimaride, farklı görevler için özelleşmiş modüller (örn. algılama için sinir ağı, akıl yürütme için kural tabanlı sistem) ardışık veya paralel şekilde çalışır. Genellikle bir **sinir ağı çıktımasını sembolik bir motora besleyen** iki aşamalı düzen şeklinde görülür⁴⁵. Örneğin, görsel sahneleri anlayan bir hibrit sisteme derin bir evrişimsel ağ önce görüntünden nesneleri ve özellikleri algılar, sonra bir sembolik mantık motoru bu algılar üzerinde çıkarır yaparak “Bardak masanın üzerinde ve masa lambanın altındadır” gibi ilişkileri kurar⁶. IBM'in görsel mantık çıkarımı yapan NSCL sistemi bu yapıya örnektir ve **nöral algı + sembolik mantık** kombinasyonunun etkinliğini kanıtlamıştır⁴⁶. Benzer şekilde, DeepMind'in AlphaGo/AlphaZero satranç ve go oynayan sistemleri, derin sinir ağlarını insan bilgi ve arama algoritmalarıyla birleştiren modüler hibrit mimarilere örnek verilebilir – sinir ağı hamleleri değerlendirdirken, klasik **ağaç arama algoritması** (Monte Carlo Tree Search) stratejik planlama yapmaktadır. Bu tür modüler hibritler, karmaşık karar problemlerinde her alt problemin en iyi yöntemle çözülmesini sağlar.
- **Öğrenmede Sembolik Yönlendirme:** Bu mimaride sembolik bilgi, sinir ağlarının eğitim sürecine rehberlik eder. Yani öğrenme sürecine **ön bilgi** veya kural enjekte edilir. Örneğin, bir dil işleme modelini eğitirken elimizde bir **bilgi grafiği** veya mantıksal kural seti varsa, ağı eğitirken hata fonksiyonunu bu kurallara göre şekillendirebiliriz⁴⁷. Diyelim elimizde “Eğer yağmur yağıyorsa zemin ıslak olur” gibi bir mantık kuralı var; salt veriyle eğitilen bir model bazen bu tutarlılığı öğrenemeyebilir. Hibrit bir yaklaşımla, modele bu kuralı yerleşik hale getiren bir mekanizma eklenir. *Sembolik yönlendirme*, özellikle verinin kısıtlı olduğu durumlarda öğrenmeyi hızlandırır ve genel hataları azaltır^{48 49}. Örnek bir uygulama olarak, bir duyu analizi modelinde önceden tanımlanmış kelime listeleri veya dilbilgisel kurallar eğitimde kullanılarak modelin az veriyle daha doğru sonuç vermesi sağlanabilir⁵⁰. Tıp alanında ise, bir makine öğrenimi təşhis sistemini eğitirken tıbbi ontolojilerden veya karar ağaçlarından gelen bilgiler, modelin arka plan bilgisini güçlendirerek eğitim verisinin daha etkin kullanılmasını sağlayabilir^{51 52}. Bu mimaride esas olan, insan uzmanlığının temsil ettiği kural/ontoloji/şablonların, sinir ağını karar sınırlarını biçimlendirmede kullanılmıştır.
- **Diferansiyellenebilir Mantık Katmanları:** Daha yeni ve gelişmekte olan bir mimari, **mantık kurallarının sinir ağı yapısına gömülmesi** ile ilgilidir. Burada amaç, uçtan uca öğrenme sırasında ağını içinde mantıksal birimlerin de eğitilebilir olmasınıdır. Örneğin, *DeepProbLog* veya *Logic Tensor Networks* gibi çerçeveler, geleneksel mantık programlama yapısını (örn. Prolog kuralları) diferansiyellenebilir hale getirerek bunu derin ağlarla birleştirir⁵³. Böylece ağı, gerçel sayılar dünyasında öğrenirken, bir yandan da mantıksal tutarlılığı sayısallaştırılmış bir şekilde göz önünde bulundurur. Bir uygulamada, görüntülerden çıkarılan özelliklerin belirli kuralları sağlaması istenebilir; mantık katmanı, bu kuralların ihlalini bir hata olarak tanımlar ve geri yayılım (backpropagation) esnasında ağı parametreleri buna göre ayarlanır¹². Örneğin otonom sürüsüz için eğitilen bir ağı, “kırmızı ışıkta geçme” kuralını öğrenmesi isteniyorsa, bu kural

mantıksal bir ifade olarak ağa entegre edilebilir ve ihlal edildiğinde eğitim cezası uygulanır. Bu sayede model, hem veriden öğrenir hem de kritik güvenlik kurallarını içselleştirir. Yapılan çalışmalar, bu yaklaşımın **toksik ya da mantıksız model çıktılarının azaltılmasında** etkili olduğunu göstermektedir; zira model, insanlarca belirlenen mantık çerçevesinin dışına çıktıığında bunu bir hata olarak görüp kendini düzeltmeyi öğrenir¹². Diferansiyellenebilir mantık mimarileri, AI sistemlerinin *hem öğrenebilir hem de katı kurallara uyabilir* olmasını hedefleyerek, özellikle **emniyet kritik** uygulamalarda (örn. tıp, otomotiv) büyük potansiyel taşıır.

• **İnsan-Döngülü Hibrit Sistemler:** Teknik olarak biraz farklı bir boyut olsa da mimaride insan etkileşimi vurgulamak önemlidir. Burada AI modeli ile insan uzman birlikte karar verir ve sistem tasarımları buna göredir. Hibrit zekâ kavramının bir boyutu da, **yapay zekâ + insan zekâsının birleşimi** olarak tanımlanır^{54 55}. Mimarının teknik yönü, modelin arayüze şeffaf bilgi sunması ve insan geri bildirimini alacak şekilde tasarlanmasıdır. Örneğin, tıbbi bir karar destek hibritinde model önerisini bir açıklama ile sunar; doktor bu öneriyi kabul veya reddeder ve sistem bu geri bildirimi öğrenmesine katar. Böyle bir hibrit sistem, **etkileşimli bir çevrim** şeklinde çalışır ve insan uzman ile AI'nın güçlü yanlarını bütünlüğe getirir. Yapılan araştırmalar, bu tür insan-AI işbirliği mimarilerinin üretimde ve planlamada verimi yükselttiğini ve kullanıcıların sisteme güvenini artırdığını göstermektedir^{54 55}.

Örnek Uygulama Sistemleri: Yukarıda anlatılan mimari prensipler, hali hazırda çeşitli sistemlerde başarıyla uygulanmıştır. Örneğin, **AlphaGeometry** adı verilen 2023 çıkışlı bir sistem, *Olympiad* seviyesindeki geometri problemlerini çözmek için hibrit bir yaklaşım kullanır: Milyonlarca ispat ve teorem örneği üzerinde eğitilmiş bir dil modeli, bir geometri problemine ilişkin mantıksal ipuçlarını üretir; sonrasında bunlar bir *sembolik ispat arama motorunu* yönlendirmek için kullanılır⁵⁶. Bu şekilde hibrit sistem, ne tamamen bir arama motorunun kör gücüne ne de tamamen bir dil modelinin sezgisel tahminine dayanır; ikisinin sinerjisiyle şimdiden sadece insan seviyesinde çözülür denilen problemleri çözebilmektedir⁵⁶. Başka bir örnek, **AlphaCode** ve **OpenAI Codex** gibi kod üreten modellerdir. DeepMind'in AlphaCode sistemi, kod üretmek için derin öğrenmeyi kullanırken, üretilen kodları test etmek ve mantıksal olarak doğrulamak için *sembolik program analizcileri* çalıştırır; bu sayede hatalı veya optimize edilmemiş kodlar elenir⁵⁷. Benzer şekilde OpenAI'ın Codex modeli, kod yazdıktan sonra çıktısını değerlendirmek üzere bir dizi *sembolik geribildirim döngüsü* kullanarak mantık hatalarını düzeltmeye çalışır⁵⁷. Bu hibrit yaklaşım, yazılım geliştirmede AI kullanımını daha güvenilir hale getirmektedir. **Otonom araçlar** da hibrit AI'nın somut bir uygulamasıdır: Bir kendi kendine sürüs sistem, görüntü tanıma için derin sinir ağlarını kullanırken (ör. yayaları, diğer araçları tanımak için), araç kullanma kurallarını ve mantıksal planlamayı sembolik bir katmanda ele alır (ör. harita verisi üzerinde rota planlama, trafik kurallarına uyma)⁵⁸. Sonuçta araç, hem karmaşık görsel algı görevlerini başarıyla hem de insan bilgisine gömülü sürüs kurallarını ihlal etmez – bu da **güvenlik ve açıklanabilirlik** açısından kritik bir gerekliliktir.

Sonuç olarak, hibrit yapay zeka modelleri mimari açıdan klasik tekil AI sistemlerinden daha karmaşık olsa da, bu karmaşılık onların gücüdür. Doğru tasarlandığında hibrit mimariler, farklı AI yaklaşımlarının en iyi yönlerini bir araya getirerek **güçlü, esnek ve güvenilir** sistemler ortaya çıkarır^{25 59}. 2024 ve sonrasında yayımlanan saygın araştırmalar, hibrit model stratejisinin yapay zekâda bir sonraki sıçramayı mümkün kılabileceğine işaret etmektedir. Tek başına bir yöntemle aşılamayan engeller, birleşik yaklaşımalarla aşılmakta; örneğin bir model hem öğrenip uyum sağlayabilmekte, hem de mantık yürüterek gereklilerini sunabilmektedir^{59 3}. Bu da hibrit YZ'yi, dar alana özel tekil zekâlardan daha **genel amaçlı ve anlaşılır** bir yapay zekâ vizyonuna doğru önemli bir adım haline getirmektedir.

Kaynakça: Güncel hibrit YZ gelişmelerine dair bilgiler; 2024-2025 yıllarında yayımlanan hakemli çalışmalar, konferans bildirileri ve arXiv ön baskılarından derlenmiştir. Örnek olarak, nöro-simgeci AI'nın son durumu Colelough ve Regli (2024) tarafından sistematik bir incelemeye ele alınmıştır^{60 11}. Fizik-

temelli hibrit modellemeye ilişkin en yeni yaklaşımlar iklim ve hidroloji alanındaki çalışmalarında sunulmuş, örneğin Huynh ve ark. (2025) hidrolojide diferansiyellenebilir fiziksel modelleri sınır ağlarıyla birleştirmiştir ²⁰ ²¹. Bilgi grafikleri ve büyük dil modellerinin entegrasyonu, Zhao (2024) gibi araştırmacıların çalışmalarında incelenmiştir. Derin öğrenme ile bulanık mantığın birleşimi Yeganejou ve ark. (2024) tarafından DCNFIS mimarisyle ortaya konmuştur ²². Ayrıca AAAI-MAKE 2025 sempozyumu bildirileri, hibrit yapay zeka ve bilgi mühendisliği bütünlüğe dair en yeni eğilimleri kapsamaktadır ³⁷. Bu kaynaklar ve burada adı geçen diğer çalışmalar, hibrit AI modellerinin tasarımları ve uygulanmasına dair en son bilgileri sunmaktadır. Bu alandaki gelişmeler, yapay zekâının gelecekte **daha açıklanabilir, güvenilir ve çok yönlü** sistemlere evrilmesinde hibrit yaklaşımın merkezi bir rol oynayacağını göstermektedir.

[1 2 3 4 5 13 14 15 16 30 35 58 What is hybrid AI? - Information Age](https://www.information-age.com/what-is-hybrid-ai-123512053/)

<https://www.information-age.com/what-is-hybrid-ai-123512053/>

[6 23 24 25 26 45 46 47 48 49 50 51 52 53 57 59 Combining Symbolic AI and Neural Networks for Real-World Complexity](https://www.cloudthat.com/resources/blog/combining-symbolic-ai-and-neural-networks-for-real-world-complexity)

<https://www.cloudthat.com/resources/blog/combining-symbolic-ai-and-neural-networks-for-real-world-complexity>

[7 8 9 10 11 12 56 60 Neuro-Symbolic AI in 2024: A Systematic Review](https://arxiv.org/html/2501.05435v1)

<https://arxiv.org/html/2501.05435v1>

[17 18 19 39 40 41 42 43 44 Hybrid Physical Models | Climate Change AI](https://www.climatechange.ai/subject_areas/hybrid_physical_models)

https://www.climatechange.ai/subject_areas/hybrid_physical_models

[20 21 38 EGUsphere - A Distributed Hybrid Physics-AI Framework for Learning Corrections of Internal Hydrological Fluxes and Enhancing High-Resolution Regionalized Flood Modeling](https://egusphere.copernicus.org/preprints/2025/egusphere-2024-3665/)

<https://egusphere.copernicus.org/preprints/2025/egusphere-2024-3665/>

[22 33 34 DCNFIS: Deep Convolutional Neuro-Fuzzy Inference System](https://arxiv.org/html/2308.06378v3)

<https://arxiv.org/html/2308.06378v3>

[27 28 29 36 jetir.org](https://www.jetir.org/papers/JETIR2408685.pdf)

<https://www.jetir.org/papers/JETIR2408685.pdf>

[31 32 54 55 Hybrid intelligence – systematic approach and framework to determine the level of Human-AI collaboration for production management use cases | Production Engineering](https://link.springer.com/article/10.1007/s11740-024-01326-7)

<https://link.springer.com/article/10.1007/s11740-024-01326-7>

[37 Machine Learning and Knowledge Engineering for Trustworthy Multimodal and Generative AI \(AAAI-MAKE 2025\) • AAAI-MAKE](https://www.aaai-make.info/)

<https://www.aaai-make.info/>