

# “Bayesian Networks in Radiology” Makalesinin Derinlemesine Analizi

## Klinik Problem ve Hedef

**Makalenin Odaklandığı Tıbbi Sorun:** Radyolojide tanı ve karar verme sürecinin zorluğu, çok sayıda farklı veri türünün ( Görüntü bulguları, klinik bilgiler, laboratuvar sonuçları vb.) bir arada değerlendirilmesini gerektirir <sup>1</sup>. Radyologlar bir görüntüdeki anormallikleri hastanın klinik durumu ile birleştirerek doğru teşhise ulaşmak zorundadır. Makale, spesifik bir tek hastalık yerine genel olarak **radyolojik tanı destek sistemleri** üzerine odaklanır. Özellikle, **yapay zekâ tabanlı bir karar desteği** ile görüntü bulgularını hastanın klinik bilgileriyle bütünlüğe getirerek **ayırıcı tanıya ulaşma** ve **klinik karar verme** problemini ele alır <sup>2</sup>. Bu kapsamda, çeşitli klinik senaryolarda Bayesien ağların nasıl uygulandığı öneklendirilmektedir. Örneğin:

- **Karaciğer lezyonlarının tanısı:** DAFODILL isimli bir karar destek modeli, karaciğerde 14 farklı lezyonu sekiz MRI bulgusu ve dört klinik parametre yardımıyla ayırt etmeye amaçlamıştır <sup>3</sup>.
- **Akut apandisit teşhisi (çocuklarda):** Bir Bayesien ağ modeli, çocuk hastalarda akut apandisit tanısını dört ultrason bulgusu (ör. apendiks çapı, duvar hiperemisinin varlığı) ve dokuz klinik/laboratuvar değişkenine (ör. ateş, ağrı süresi, CRP seviyesi) dayanarak desteklemiştir <sup>4</sup>. Bu model, eksik veriler olsa bile olasılık hesaplayabilmiş ve belirli vaka örneklerinde %97 olasılıkla apandisit olduğu sonucunu üretebilmiştir <sup>5</sup>.
- **Kemik tümörlerinin benign-malign ayımı:** Nadir görülen primer kemik tümörlerinde tanı zordur. Bir Bayesien ağ, yaş, cinsiyet ve 17 radyografik özellik kullanarak beş benign ve beş malign kemik tümörünü doğru ayırt etmeye başarmıştır <sup>6</sup>. Başka bir çalışmada, naif Bayes yöntemi ile 1664 vaka üzerinde 29 farklı kemik tümörü tipi %44 doğrulukla (ilk tahminde) teşhis edilmiş; doğru tanıyı ilk üç olası tanı içinde verme oranı %60 olarak raporlanmıştır <sup>6</sup> <sup>7</sup>.
- **Meme görüntülemesinde kanser riski tahmini:** Meme röntgeni raporlarındaki standart BI-RADS bulgularını ve klinik risk faktörlerini kullanarak meme kanseri olasılığını hesaplayan Bayesien ağ tabanlı sistemler geliştirilmiştir <sup>8</sup>. Örneğin, **MammoNet** adlı sistem yedi klinik özellik ve 15 mamografi bulgusu üzerinden meme kanseri varlığını tahmin etmektedir <sup>8</sup>.

Bu örneklerin ortak noktası, **farklı türdeki verilerin entegre edilerek tanı destek kararlarının verilmesi** problemidir. Makale, bu klinik soruna çözüm olarak **Bayesien ağlar** (Bayesian networks) adlı yapay zekâ yaklaşımını ele almaktadır. Bayesien ağlar, **belirsizlik altında akıl yürütme** yaparak doktorlara karar sürecinde yardımcı olmayı hedefler <sup>9</sup> <sup>10</sup>. Bu sayede radyologlar, karmaşık olguları değerlendirdikten sonra Bayesien ağların sağladığı **objektif olasılık hesaplamalarından** ve **önerilerden** faydalananabilir.

## Yapay Zekâ Yöntemleri ve Model Mimarileri

**Kullanılan Yapay Zekâ Yaklaşımı:** Makalenin ana odak noktası **Bayesien Ağlar (Bayesian Networks)** olarak adlandırılan bir yapay zekâ modelidir. Bayesien ağlar, 1980'lerin ortasında tanıtılmış ve özellikle **olasılıksal grafik modeller** sınıfına giren bir yöntemdir <sup>9</sup>. Bu model, **yönlendirilmiş asılık grafik** (directed acyclic graph, DAG) yapısı ile değişkenler arası **olasılıksal ilişkileri** temsil eder <sup>11</sup> <sup>12</sup>. Her bir **düğüm (node)** bir değişkeni (örneğin bir hastalığın varlığı/yokluğu veya bir görüntü bulgusunun mevcut/değil oluşu) temsil ederken; düğümler arasındaki **oklar (kenarlar)** bu değişkenler arasındaki

nedensel veya olasılıksal etkileşimi gösterir<sup>12</sup> <sup>13</sup>. Her düğüme ait bir **Koşullu Olasılık Tablosu (Conditional Probability Table, CPT)** bulunur; bu tablo, ilgili değişkenin alabileceği değerlerin, ebeveyn düğümlerinin belirli durumları altında hangi olasılıklara sahip olduğunu tanımlar<sup>14</sup> <sup>15</sup>. Örneğin, bir Bayes ağı modeli **meme kanseri** senaryosu için Şekil 1'de gösterilmiştir. Bu ağıda *Yaş, Meme Kanseri ve Mamografi Sonucu* olmak üzere üç düğüm ve aralarındaki olasılıksal ilişkiler görülmektedir<sup>16</sup> <sup>17</sup>. *Yaş* düğümünün beş olası aralığına (ör. 40-49, 50-59 vb.) ön olasılıklar atanmıştır; **Meme Kanseri** düğümünün "var" ya da "yok" olma durumları, hastanın yaşı tarafından etkilenmektedir; **Mamografi Sonucu** (normal veya anomal) ise kanserin varlığına bağlı bir test sonucudur. Bu yapı içerisinde, oklar nedensel etkinin yönünü gösterir (örneğin kanser → mamografi sonucu okuya, mamografi sonucunun olasılıkları kanserin varlığına göre belirlenir). Bayes ağı, herhangi bir düğümün durumu bilindiğinde (ör. hastanın 70 yaş üzerinde olması gibi) diğer düğümlerin olasılık dağılımını **Bayes kuralı** ile güncelleyebilir; örneğin hastanın 70+ yaşında olduğu bilgi olarak girildiğinde meme kanseri ihtimali %1.26'dan %2.60'a yükselir, ek olarak mamografinin anomal olasma概率 de verildiğinde bu ihtimal %32.5'e çıkar<sup>18</sup> <sup>19</sup>. Bu örnek, Bayesien ağların **öncül olasılıklardan şartlı olasılıklara geçerek tanısal çıkarımlar yapabildiğini** göstermektedir.

*Şekil 1: Basit bir Bayesien ağ örneği – Hastanın yaşı, meme kanseri varlığı ve mamografi sonucu arasında olasılıksal ilişkiler. Gri renkteki düğümler gözlemlenmiş bilgileri (hastanın 70 yaşından büyük olması ve mamografinin anomal olasma概率) gösterirken, beyaz renkteki düğüm bilinmeyen değişkeni (kanser durumu) temsil eder. Oklar, nedensel/olasılıksal etki yönünü belirtir; örneğin meme kanserinden mamografi sonucuna doğru olan ok, mamografinin anomal olasma概率ının kanserin varlığına bağlı olduğunu gösterir. Model, girilen kanıtlar ışığında meme kanseri olasılığını güncelleyebilir: Hiçbir bilgi yokken kanser olasılığı %1.26 iken, 70+ yaş bilgi olarak girildiğinde %2.60'a, ek olarak anomal mamografi sonucu girildiğinde %32.5'e yükselmektedir<sup>18</sup> <sup>19</sup>.*

Makaledeki temel yapay zekâ yöntemi Bayesien ağlar olsa da, **derin öğrenme** (özellikle **Convolutional Neural Network – CNN**, eşişimsel sinir ağı) gibi yöntemlere de atif yapılmaktadır. Bayesien ağlar **görüntü tanıma (bilgisayarlı görme)** problemine doğrudan uygulanamazken<sup>20</sup>, **hibrit yaklaşımlar** ile derin öğrenmenin ve Bayesien ağların bir arada kullanılması önerilmektedir<sup>21</sup> <sup>22</sup>. Bu hibrit mimaride, **CNN gibi derin öğrenme modelleri** ham tıbbi görüntülerdeki lezyonları veya anomalileri otomatik olarak saptayıp nicel özellikler çıkarırken; **Bayesien ağ** ise bu çıkarılan görüntü özelliklerini hastanın yaşı, cinsiyeti, klinik belirtileri, laboratuvar değerleri gibi diğer verilerle entegre ederek **tanıyı oluşturmaktadır**<sup>23</sup> <sup>24</sup>. Bu, radyologların gerçek hayatı izlediği iki adımlı süreci (önce görüntünden bulguların tanınması, sonra klinik bağlam ile yorumlanması) taklit eden bir mimaridir<sup>25</sup> <sup>26</sup>.

Makale ayrıca Bayesien ağların **diğer makine öğrenimi yöntemleriyle** ilişkisini de tartıĢır. Bayesien ağlar, derin sinir ağlarının yanı sıra **karar ağaçları, destek vektör makineleri (SVM)** veya **kümeleme algoritmaları** gibi yöntemlere alternatif veya tamamlayıcı olarak kullanılabilir<sup>27</sup>. Örneğin, karar ağaçları belirli kurallara göre dallanarak sonuca varırken, Bayesien ağlar tüm olasılıkları hesaplayarak daha esnek bir çıkarım sunabilir. **Naif Bayes** gibi basitleştirilmiş Bayes modelleri, Bayesien ağların özel bir türüdür (tek bir neden düğümün birden fazla belirtiye etkisi varsayımlıyla). Makalede bahsedilen meme kanseri risk hesaplamasında **ağaç-genişletilmiş naif Bayes (tree-augmented naive Bayes)** modeli kullanılmıştır<sup>28</sup> <sup>29</sup>. Ayrıca **Bayesien sinir ağları** kavramına de ğinilerek, klasik sinir ağlarının eğitiminin Bayesian çıkarım prensipleriyle yapılmasının (ağırlıklara olasılıksal bir yaklaşım getirilmesinin) mümkün olduğu belirtilmektedir<sup>30</sup>. Ancak bu konu makalede derinlemesine işlenmemiĢtir, sadece Bayes yaklaşımının farklı AI çerçevelerine entegre edilebileceğine dair bir örnek olarak sunulmuştur.

## Veri Kaynakları, Veri Ön İşleme ve Veri Büyüklüğü

**Veri Kaynakları:** Bayesien ağlar, **çeşitli kaynaklardan gelen heterojen verileri** kullanabilir. Makalede ele alınan uygulamalarda kullanılan veriler şunları içerir: tıbbi görüntülerden elde edilen bulgular (örn. **MRI ve röntgen incelemelerindeki özellikler**), **hastaya ait klinik bilgiler** (yaş, cinsiyet, semptomlar, fizik muayene bulguları), **laboratuvar sonuçları** (kan değerleri gibi) ve **epidemiolojik veriler** (risk faktörleri, aile öyküsü vb.) <sup>1</sup> <sup>4</sup>. Örneğin, apandisit modelinde hastanın ateşi, semptom süresi, CRP seviyesi gibi klinik veriler; meme kanseri modellerinde ise hastanın yaşı, aile öyküsü gibi risk faktörleri ve mamografiden elde edilen bulgular birlikte kullanılmıştır <sup>4</sup> <sup>8</sup>. Bazı modeller tamamen **literatürden elde edilen olasılık değerlerine** dayandırılmıştır: Örneğin safra kesesi hastalıklarını değerlendiren bir Bayesien ağ modeli, tıbbi yayınlardaki prevalans ve ilişki verilerini kullanarak oluşturulmuştur (bu model, hasta yaşı, cinsiyeti, görüntü ve fizik muayene bulgularını literatür olasılıklarıyla birleştirmiştir) <sup>31</sup> <sup>32</sup>. Dolayısıyla, Bayesien ağlar için veri kaynağı olarak geniş bir yelpaze söz konusudur: *büyük ölçekli veri tabanları* (ör. on binlerce mamografinin sonuçlarını içeren kayıtlar <sup>33</sup>), *küçük ölçekli ancak iyi tanımlanmış veri setleri* (ör. nispeten az sayıda çocuk hasta verisiyle apandisit modeli <sup>4</sup>), ya da *uzman bilgisi ve literatür değerleri* (ör. safra kesesi modeli <sup>31</sup>).

**Veri Büyüklüğü:** Makale, Bayesien ağların **büyük veri gereksinimi olmadan da çalışabildiğini** vurgulamaktadır. Geleneksel derin öğrenme modelleri genellikle binlerce hatta on binlerce örnek isterken <sup>34</sup> <sup>35</sup>, Bayesien ağlar **küçük veri setleriyle makul sonuçlar üretebilir** <sup>36</sup> <sup>37</sup>. Örneğin kemik tümörü tanısındaki naif Bayes yaklaşımı 1664 vakadan öğrenim görerek 29 farklı tanıyı belirli doğrulukla ayırt edebilmiştir <sup>7</sup>. Meme görüntülemesinde Burnside ve ark.'nın çalışması ise büyük bir veri setine (48.000'den fazla mamografi) dayanarak ağaç-genişletilmiş naif Bayes modeli oluşturmuştur <sup>33</sup>. Yani Bayesien ağlar, **hem çok büyük veri tabanlarından öğrenebilecek esnekliğe sahip** (veri varsa bunu kullanabiliyor) **hem de veri az olduğunda uzman bilgisiyle desteklenerek çalışabiliyor**. Bu özellik, nadir görülen hastalıklarda veya toplamak zor olan verilerde BN'leri avantajlı kılar; örneğin nadir bir hastalık için literatürdeki olasılık değerleriyle bir model kurulabilir, derin öğrenmede ise aynı başarı için yeterli sayıda örnek bulmak imkânsız olabilir <sup>22</sup> <sup>38</sup>.

**Veri Ön İşleme:** Bayesien ağlar çoğunlukla **sayısal sürekli veriler yerine kategorik (ayırık) verilerle** çalışır. Bu nedenle, modelde kullanılacak sürekli değişkenler genellikle **diskretize edilir** <sup>39</sup> <sup>20</sup>. Örneğin yaş veya laboratuvar değerleri, belirli aralıklara bölünerek kategori haline getirilir (Şekil 1'deki yaş düşüğünde olduğu gibi farklı yaş aralıkları tanımlanması <sup>16</sup>). Bu diskretizasyon işlemi önemli bir ön işleme adımıdır ve uygun aralıkların seçimi modelin performansını etkileyebilir. Makale, Bayesien ağların yalnızca sınırlı sürekli dağılımları (koşullu Gauss dağılımı gibi) desteklediğini, dolayısıyla genellikle diskretizasyonun zorunlu olduğunu belirtir <sup>20</sup> <sup>40</sup>. Bunun yanı sıra, **metin veya görüntü verilerinin yapısal özelliklere dönüştürülmesi** de ön işleme kapsamında değerlendirilebilir. Örneğin, bir çalışma metin halindeki mamografi raporlarından BI-RADS bulgularını **doğal dil işleme (NLP)** ile otomatik çekip Bayesien ağa beslemiştir <sup>41</sup>. Benzer şekilde ham görüntülerde lezyon tespiti için bir derin öğrenme modeli kullanılıp, çıkan özellikler Bayesien ağ girdi verisine dönüştürülebilir <sup>23</sup> <sup>42</sup>.

Veri ön işlemenin bir diğer boyutu, **eksik verilerle başa çıkma** konusudur. Bayesien ağlar, eksik veriler durumunda dahi çıkarım yapabilir; çünkü modelde bilinmeyen değişkenler olduğunda, mevcut bilgilere dayanarak eksik kalanları marginalize ederek (göz ardı ederek) hesap yapar. Makaledeki çocukların apandisit örneğinde, bazı klinik veya görüntüleme verileri mevcut olmasa bile model geriye kalan bilgilerle olasılık hesaplayabilmiştir <sup>43</sup>. Bu, pratikte sık karşılaşılan eksik veri sorununa karşı BN'lerin dayanıklılığını gösterir. Özette, veriler Bayesien ağa girilmeden önce **uygun şekilde kategorilere ayrılır, görüntü ve serbest metin gibi ham kaynaklardan anlamlı özellikler çıkartılır, ve varsa eksik değerler yönetilir**. Model kurulurken ayrıca uzmanlardan alınan bilgiler de veri olarak değerlendirilebilir (ör. bir koşullu olasılık tablosunun değerleri literatürden veya uzman tahmininden konabilir).

# Model Eğitimi: Stratejiler, Optimizasyon Teknikleri ve Hiperparametreler

**Model Oluşturma ve Eğitimi:** Bayesien ağların eğitimi, iki temel bileşeni içerir: **yapı öğrenimi** (hangi düğümlerin nasıl bağıntılı olduğunu belirleme) ve **parametre öğrenimi** (koşullu olasılık tablolarındaki değerleri belirleme)<sup>44 45</sup>. Makaleye göre Bayesien ağ modelini kurarken **esnek bir yaklaşım** benimsenebilir: Tamamen insan uzmanlığı ile manuel olarak modellenebilir, tamamen veri odaklı otomatik öğrenme ile çıkarılabilir veya bu ikisinin bir karışımı uygulanabilir<sup>44 46</sup>.

- **Yapı (Model Topolojisi) Öğrenimi:** Bu, ağıdaki düğümlerin birbirine nasıl bağlanacağını bulma problemdir. Makalede, literatürde kullanılan üç ana yaklaşım belirtilmiştir:
  - **Skor-tabanlı arama algoritmaları:** Bu yöntemler olası ağ yapıları arasından en iyi skoru (genellikle veriye uygunluk ölçütü olarak BIC, AIC gibi kriterler) veren yapıyı ararlar<sup>45</sup>. Arama uzayı çok büyük olduğu için, genellikle **heuristic** (sezgisel) optimizasyon teknikleri kullanılır. Örneğin, *hill climbing* (*tepe tırmanma*), *simulated annealing* (*benzetimli tavlama*) veya *genetik algoritmalar* gibi yöntemler, ağ yapısını adım adım iyileştirerek yüksek skorlu bir çözüm ararlar.
  - **Kısıt-tabanlı (constraint-based) algoritmalar:** Bu yaklaşım, veride yapılan **koşullu bağımlılık-bağımsızlık testlerine** dayanır<sup>45</sup>. Veri içindeki değişken çiftlerinin istatistiksel bağımlılık ilişkileri analiz edilerek, hangi düğümler arasında muhtemel bir kenar olabileceği belirlenir. Örneğin, *PC algoritması* bu mantıkla çalışan klasik bir yöntemdir: İstatistiksel olarak anlamsız görünen kenarlar elenir, anlamlı olanlar yönlendirilir.
  - **Bayesien yöntemler:** Bu metod, olası ağ yapıları üzerinde bir **olasılık dağılımı** tanımlayarak, veri verildiğinde en olası yapıları çıkarır<sup>45</sup>. Farklı ağ yapılarına bir ön (prior) dağılım konur ve veri görülünce posterior olasılık dağılımı hesaplanır; böylece birden fazla yüksek-olasılıklı yapı elde edilebilir (bir **yapı ansamblesi**). Bu yöntem, model belirsizliğini de yansıttığı için değerlidir ancak hesaplama maliyeti yüksektir.  
Makalede, yapı öğrenimiyle ilgili ayrıntılara girilmemiği ve konunun kapsam dışı olduğu belirtilmiş, daha derin bilgi için ilgili kaynaklara atıf yapılmıştır<sup>45</sup>. Bu da, temel olarak, Bayesien ağ yapısının ya uzman bilgisi ile **elle çizileceğini** (ör. doktorlar bilir ki belirli bir bulgu belirli bir hastalığın göstergesidir, bunu ağıda kenar olarak ekler), ya da **veriyle otomatik bulunabileceğini**, pratikte de çoğunlukla **yarı otomatik bir yolun** seçildiğini ima etmektedir. Örneğin bir uzman, ağıın ana hatlarını çizer, sonra veri kullanılarak ince ayar yapılır.
- **Parametre Öğrenimi:** Ağ yapısı belirlendiğten (veya kabul edildikten) sonra, her bir düğümün koşullu olasılık tablosundaki sayısal değerlerin eğitim verisinden hesaplanması gereklidir<sup>47</sup>. Tam veri durumunda, parametre öğrenimi genellikle basit **sık olasılıkçı (frekansiyel) yöntemlerle** yapılır: Veri içinde bir düğümün belirli bir kombinasyonda görülmeye sıklığı sayılır ve ilgili olasılıklar bu frekans oranlarına göre hesaplanır (temel anlamda maksimum likelihood tahmini). Eğer veri eksikse veya gizli değişkenler varsa, **EM algoritması** gibi teknikler parametre tahmininde kullanılabilir (makalede bu açıkça bahsedilmemiş olsa da Bayesien ağ literatüründe bilinen bir yöntemdir). Makale, **Burnside ve ark.** tarafından yapılan bir çalışmayı örnek veriyor: 48 bin mamografinin bulunduğu bir verisetiyle bir Bayesien ağıın parametreleri otomatik olarak öğrenilmiş ve model meme kanseri tahmininde başarıya ulaşmıştır<sup>33 29</sup>. Ayrıca, hem yapının hem parametrelerin birlikte veriden öğrenilebildiği vurgulanmıştır<sup>48</sup>. Bu noktada, **ağ yapısını ve olasılıkları aynı anda optimize eden** tekniklerden (ör. yapısal EM algoritması gibi) literatürde bahsedildiği not düşülür.
- **Kombine (Melez) Öğrenme:** Makale, pratikte **uzman bilgisi ile veri öğreniminin harmanlanabileceğini** altını çiziyor<sup>49</sup>. Bu yaklaşımda, bazı olasılık değerleri uzmanlarca veya

literatürden belirlenir, geri kalan kısımlar veriyle doldurulur. Örneğin bir doktor çok nadir bir durumun ön olasılığını literatüre dayanarak ağa koyabilir, daha sık görülen kısımları ise veri seti istatistiksel olarak belirler. Makalede bahsi geçen **Laplace düzeltmesi (smoothing)** de bir hiperparametre tekniği olarak karşımıza çıkar<sup>50</sup>. Laplace düzeltmesinde her bir olasılık tablosu hücresine küçük bir  $\lambda$  değeri eklenderek, eğitim verisinde sıfır kez görülen olgulara sıfır olasılık değeri verilmesi engellenir<sup>50</sup>. Örneğin  $\lambda=1$  alınarak (sıklıkla *Laplace estimatör* olarak bilinir) her bir kategoriye bir “sanal örnek” eklendir ve olasılıklar yeniden hesaplanır. Bu sayede aşırı uyum (overfitting) önlenir ve model hiç görmediği durumlar için bile düşük de olsa bir olasılık atayabilir<sup>51</sup>. Laplace düzeltmesi, Bayesien ağlarda yaygın kullanılan bir **hiperparametre** yöntemidir;  $\lambda$  değeri kullanıcı tarafından belirlenir (genelde 1 veya düşük bir pozitif değer seçilir).

**Optimizasyon ve Hiperparametre Ayarları:** Bayesien ağların eğitimi sırasında klasik derin öğrenmede olduğu gibi öğrenme oranı, epoch sayısı gibi hiperparametreler bulunmaz; ancak yukarıda bahsedilen  $\lambda$  gibi **düzeltme katsayıları, yapı arama algoritmaları için parametrik seçenekler** (ör. arama süresini kısaltmak için kenar sayısı sınırı, skor fonksiyonunun seçimi gibi) mevcuttur. Makalede, bu detaylar derinlemesine tartışılmamış, ancak Bayesien ağ modelinin eğitiminin nispeten veri azlığına toleranslı olduğuna dikkat çekilmiştir<sup>36</sup>. Ayrıca **dinamik Bayesien ağlar** kavramına deñinilerek, zaman içinde tekrarlanan durumlar için yapının kopyalanıp bir **zaman serisi modeli** oluşturulabileceği belirtilmiştir (örneğin bir hastanın zaman içindeki tarama sonuçlarına bakarak akciğer kanseri riskini sürekli güncelleyen bir model geliştirilmiştir)<sup>52 53</sup>. Dinamik Bayesien ağlar, parametre öğrenimini her zaman dilimi için yaparken aynı zamanda bir **zamansal bağımlılık** parametresi de içerirler. Bu da bir ileri seviye hiperparametre sayılabilir (ör. zaman adımı arasındaki geçiş olasılıkları).

Özetle, **model eğitimi** konusunda Bayesien ağlar geleneksel derin öğrenme modellerinden farklı bir yaklaşım gerektirir. Ağırlıklı olarak **olasılık teorisine dayalı istatistiksel yöntemler** ve **arama/optimizasyon algoritmaları** kullanılır. Hiperparametre ayarları, yapısal kısıtlar ve olasılık tablolarının düzgünleştirilmesi gibi alanlarda yoğunlaşır. Makalede her ne kadar derin teknik detайлara girilmese de, ilgili literatüre referans vererek bu süreçlerin iyi anlaşıldığı takdirde Bayesien ağların etkin şekilde kurulabileceği vurgulanmaktadır.

## Değerlendirme Metrikleri ve Performans Sonuçları

Makale, Bayesien ağların etkinliğini göstermek üzere çeşitli çalışmaların performans sonuçlarını aktarmaktadır. **Değerlendirme metrikleri** olarak en sık **ROC eğrisi altında kalan alan (AUC)**, **doğruluk (accuracy)**, **duyarlılık ve özgüllük** gibi klasik ölçütler kullanılmış; ayrıca bazı çalışmalarında **uzman karşılaşmaları** ve **yanlış pozitif oranlarındaki azalma** gibi pratik göstergelere de yer verilmiştir. Aşağıda önemli bulgulardan bazıları listelenmiştir:

- **MammoNet (Meme Kanseri Tahmin Modeli):** Yedi klinik faktör ve 15 mamografik bulguya dayanan bu Bayesien ağ modeli, test verisindeki 67 hasta için **AUC = 0.88** performansına ulaşmıştır<sup>8</sup>. Bu, modelin ROC eğrisi altında %88'lik bir alan elde ettiği anlamına gelir ki tanı sistemleri için oldukça iyi bir doğruluk göstergesidir.
  - **Burnside ve Ark.'nın Meme Kanseri Riski Modeli:** 48 bin üzerinde mamografi ve sonuç verisi kullanılarak eğitilen **ağaç-genişletilmiş naif Bayes** modeli, bağımsız testlerde **AUC = 0.96** gibi çok yüksek bir değer yakalamıştır<sup>33</sup>. Bu model, BI-RADS kategorizasyonunu da öngörmek için kullanılmış; serbest metin raporlardan otomatik çıkarılan BI-RADS tanımlayıcıları modele girdi yapıldığında, **%98 doğrulukla** BI-RADS değerlendirme kategorisini tahmin edebilmiştir<sup>41</sup>.
- Dahası, bu sistem yardımıyla mamografideki **yanlış pozitif (false positive) yorumların %29**

**oranında azaldığı** gösterilmiştir<sup>41</sup>. Yanlış pozitiflerin azalması klinikte çok değerlidir, zira gereksiz biyopsi ve endişelerin azaltılması anlamına gelir.

• **Kemik Tümörü Tanı Sistemi:** 1664 vaka verisiyle eğitilen naif Bayes tabanlı sistem, 29 farklı kemik tümör tipini tanımda ilk tahminde %44 başarı göstermiştir; doğru tanıyı üç olası tanı listesi içinde verme oranı ise %60'tır<sup>7</sup>. Bu performans belki yüksek görünmese de, 29 sınıfı zorlu bir problemde ve sınırlı vakayla elde edilmesi dikkate değerdir. Ayrıca model, her vaka için en olası birkaç tanıyı sıralayarak doktorların ayırcı tanı listesine bilimsel bir destek sunmaktadır.

• **Hibrit Derin Öğrenme + Bayesien Ağ (Beyin MR Tanı) Uygulamaları:** Beyin MRI görüntülerinde lezyon tespiti için CNN tabanlı görüntü analizini, tanı çıkarımı için Bayesien ağı birleştiren sistemler 19 farklı beyin hastalığı (serebral hemisfer patolojileri) ve 36 farklı derin gri cevher hastalığı için test edilmiştir<sup>54</sup>. Bu yaklaşım, **ileri düzey uzman (nöroradyolog) hekimlerin seviyesine yakın** doğruluk sağlamış; genel radyologlar ve hatta bazı üst ihtisas yapan radyoloji asistanlarından **daha iyi performans** göstermiştir<sup>42 25</sup>. Yani modelin tanısal isabeti, bir süperspesyalist hekimin düzeyine ulaşırken, alanında daha az deneyimli hekimleri belirgin şekilde geride bırakmıştır. Bu, yapay zekânın doğru kurgulandığında insan performansını yakalayabildiğine dair önemli bir göstergedir.

• **Diğer Örnekler:** Makalede ayrıca triple-negatif meme kanseri riskinin öngörülmesi için 16 parametreli bir Bayesien ağ modeli geliştirildiği belirtilmiş, ancak spesifik metrik değerler verilmemiştir<sup>55</sup>. Nörolojik görüntülemeye, atipik menenjiyom, glial tümör ve metastaz ayrılmışta, gliom derecesinin öngörüsünde, multiple skleroz lezyonlarının segmentasyonunda Bayesien ağların kullanıldığı çeşitli araştırmalarдан bahsedilmiştir<sup>56</sup>. Bu çalışmaların her biri ilgili problemede belirli bir doğruluk/artış sağlamış olup, metrik detayları referanslarda bulunabilir. Önemli olan, Bayesien ağların **farklı radyoloji alanlarında uygulanıp başarılı sonuçlar elde edebildiğinin** altının çizilmesidir.

Genel olarak değerlendirildiğinde, Bayesien ağ tabanlı sistemler özellikle **AUC** gibi ayrim gücü ölçütlerinde yüksek performans sergilemiştir. Bazı uygulamalarda doğrudan **hassasiyet (sensitivity) / seçiklik (specificity)** değerleri rapor edilmemiş olsa da, AUC değerlerinin yüksek oluşu ve yanlış pozitif oranındaki belirgin düşüş gibi bulgular, bu yöntemlerin klinik olarak uygulanabilir doğrulukta olduğuna işaret etmektedir. Ayrıca **açıklanabilirlik** özellikleri sayesinde salt sayısal metriklerin ötesinde, **model çıktısının klinik olarak anlaşılabilirliği** de bir başarı kriteri olarak değerlendirilebilir.

## Karşılaştırmalı Analiz ve Karşılaştırılan Yöntemler

Makale bir derleme olduğu için doğrudan yazarların yaptığı bir deneyel karışıltırma sunmamaktadır; ancak farklı yapay zekâ yöntemleri ile Bayesien ağların avantaj ve dezavantajlarını kıyaslayarak okuyucuya bir perspektif vermektedir. **Karşılaştırmalı analiz** bağlamında öne çıkan noktalar şunlardır:

• **Derin Öğrenme (Özellikle CNN) ile Kıyaslama:** Derin sinir ağları, görüntü tanıma ve belirgi tespitinde son derece başarılı olmuş, radyolojide lezyon saptama, sınıflandırma gibi birçok alanda standart haline gelmiştir<sup>57 58</sup>. Ancak makale, derin öğrenmenin **"kara kutu"** doğasına dikkat çekiyor – yani karar verme süreçlerini açıklamaması ciddi bir handikaptır<sup>57 58</sup>. Buna karşın Bayesien ağlar, **şeffaf ve açıklanabilir** modellerdir; her bir sonucun nasıl bir olasılık hesabıyla ortaya çıktığı izlenebilir. Ayrıca derin öğrenme modelleri genellikle **çok büyük veri** gerektirirken (binlerce vakadan oluşan veri setleri)<sup>34</sup>, Bayesien ağlar **küçük verilerle de çalışabilir** ve hatta veriye dayalı öğrenim olmadan sadece uzman bilgisile bile kurgulanabilir<sup>36 37</sup>. Özetle, derin öğrenme piksel düzeyinde otomasyon sağlarken Bayesien ağlar yorumlayıcı karar desteği sunar; hibrit modeller ise ikisinin en iyilerini birleştirmeye çalışır<sup>59</sup>.

<sup>60</sup>. Makale, bu hibrit yaklaşımın özellikle beyin hastalıkları tanısında başarılı olduğunu göstererek, **her iki yöntemin birbirini tamamlayabileceğini** vurgular <sup>23</sup> <sup>42</sup>.

- **Klasik Makine Öğrenimi (Karar Ağaçları, SVM) ile Kiyaslama:** Bayesien ağlar, klasik kural tabanlı veya lineer modellerin ötesinde, **olasılıksal bir çerçeve** sunduğu için espektifdir. Karar ağaçları belirgin eşik değerlerine göre dallanır ve bir ölçüde yorumlanabilir ancak dallanma patlaması (combinatorial explosion) durumunda performansı düşebilir. SVM gibi yöntemler yüksek doğruluk sağlayabilse de sonuçları yorumlamak zordur (özellikle RBF kernel gibi karmaşık çekirdekler kullanıldığında). Makalede Bayesien ağların gerektiği gibi bu yöntemlerle **birlikte** de kullanılabileceği, örneğin bir kümeleme algoritmasıyla segmentasyon yapıldıktan sonra Bayesien ağla tanı çıkarımı gibi senaryoların mümkün olduğu ima edilmiştir <sup>27</sup>. Doğrudan performans kıyasları verilmemekle birlikte, Bayesien ağların **küçük veri + bilgi birleştirme** avantajının, karar ağaçlarının **hızlı ve veri az duyarlı** yönüyle benzer bir açığı kapattığı; SVM'nin yüksek performans gösterdiği yerlerde ise BN'nin ek açıklama kabiliyeti kattığı düşünülebilir.
- **İnsan (Radyolog) Performansı ile Kiyaslama:** Makale, bazı çalışmalarda AI modellerinin insan uzmanlarla karşılaşıldığını aktarmaktadır. Özellikle derin öğrenme ile entegre Bayesien ağ kullanan bir nöroloji uygulamasında, sistemin tanı başarısının **üst düzey uzman radyologlarla denk**, genel radyologlardan ise daha iyi olduğu belirtilmiştir <sup>42</sup> <sup>25</sup>. Bu oldukça çarpıcı bir bulgudur; yapay zekâ destekli hibrit model, deneyimli bir insan kadar doğru teşhis koyabilmisti. Öte yandan, Bayesien ağların, **hekimlerin sezgisel karar süreçlerindeki önyargıları azaltarak** daha tutarlı sonuçlar verebileceği de vurgulanır <sup>9</sup> <sup>61</sup>. Yani bir radyoloğun deneyimine veya o anki dikkat seviyesine göre değişimle kararlar, Bayesien ağ ile desteklendiğinde daha objektif ve tekrarlanabilir hale gelebilir. Bu, insan performansına kıyasla modelin **tutarlılık (consistency)** avantajını ortaya koyar.

- **Diğer Yöntemlerle Entegrasyon:** Bayesien ağlar başka AI yaklaşımlarıyla kıyaslanmaktan ziyade, onlara **entegre edilebilen bir çatı** olarak da ele alınır. Makalede, **mantık tabanlı sistemlerle** (ör. tıbbi ontolojiler, kural-tabanlı sistemler) ve **nöral ağlarla** entegrasyon çabalarından bahsedilir <sup>62</sup>. Örneğin, ontolojilerin sunduğu kavramsal çerçeveye Bayesien olasılıkların eklenmesi veya sinir ağlarının çıkışlarına BN mantığı uygulanması, farklı yöntemlerin kıyasından öte kombinasyonu anlamına gelir. Bu da Bayesien ağların **esnek bir platform** olduğunu, diğer tekniklerle yarışmaktan çok onlara katkı sağlayabileceğini gösterir.

## Klinik Uygulama Potansiyeli, Sınırlamalar ve Etik Değerlendirmeler

**Klinik Uygulama Potansiyeli:** Makale genel olarak Bayesien ağların radyolojide **karar destek sistemi** olarak önemli bir rol oynayabileceğini ortaya koyuyor. Klinik açıdan en büyük potansiyel, **çok boyutlu veriyi entegre edip doktorlara olası tanılar ve bunların olasılıkları konusunda rehberlik etmesi**. Özellikle, bir radyolog herhangi bir görüntü bulgusunu değerlendirirken hastanın tıbbi geçmişini, yaşını, laboratuvar verilerini de düşünmek zorundadır; Bayesien ağlar bu faktörlerin tümünü matematiksel bir tutarlılıkla bir araya getirip, örneğin "bu özelliklere sahip bir hastada hastalık X'in olasılığı %32, hastalık Y'nin %5, diğerlerinin toplamı %63" gibi **kantitatif destek** sunabilir <sup>2</sup> <sup>12</sup>. Bu sayısal olasılık tahminleri hekim kararını tamamen değiştirmese bile, **önemli bir ikinci görüş** veya kontrol mekanizması sağlayacaktır. Makalede sunulan BANTER ve ARIES gibi eğitim amaçlı sistemler de, Bayesien ağların tip eğitiminde bile kullanılabileceğini, genç hekimlerin tanı düşünme süreçlerini geliştirmede araç olabileceğini göstermiştir <sup>63</sup> <sup>64</sup>. Bu sistemler öğrenciye hastalık olasılıklarını hesaplatıp en faydalı tanı testini seçirmekte, ardından doğru seçimi yapıp yapmadığını ve modelin bu karara göre olasılıkları nasıl

güncellediğini açıklamaktadır<sup>65</sup> <sup>66</sup>. Böylece Bayesien ağlar, sadece tanı koymada değil, **öğretici bir destek** olarak da değerlidir.

Klinikte Bayesien ağların potansiyel bir diğer katkısı, **nadir hastalıklarda tanı atlamalarını önleme** olabilir. Deneyimli bir radyolog bile çok nadir bir hastalığı düşünmeyebilir; ancak eğer model literatürden beslenen bir ön bilgiyle bu nadir hastalığa küçük de olsa bir olasılık veriyorsa, doktorun dikkatini çekebilir. Ayrıca **gerçek zamanlı öğrenme** potansiyeli de vardır: Makale, Bayesien ağların zaman içinde **öğrenen sağlık sistemleri** ile bütünleşebileceğini vurgular<sup>67</sup> <sup>68</sup>. Model, hastaneye yeni eklenen vakalarla kendini güncelleip popülasyona uyum sağlayabilir. Örneğin, kurulan bir BN modeli hastaların gerçek sonuçlarıyla beslendikçe koşullu olasılık tablolarını ayarlayabilir, böylece kurumsal veya bölgesel farklılıklarla zamanla öğrenmiş olur<sup>68</sup> <sup>69</sup>. Bu “canlı” modeller, değişen hastalık prevalansları veya yeni tanı yöntemleri çıktıka adaptasyon gösterebilir ki bu da klinik pratikte uzun vadede büyük bir avantajdır.

**Sınırlamalar:** Bayesien ağların birçok avantajının yanında **önemli sınırlamaları** da mevcuttur. Makale özellikle şu kısıt ve zorluklara dikkat çekiyor:

- **Görüntü ve Sinyal Verilerine Doğrudan Uygulanamama:** Bayesien ağlar, temelinde tablo şeklinde yapılandırılmış ve kategorik hale getirilmiş verilerle çalıştığı için, ham görüntü piksellerini veya serbest metinleri doğrudan girdi olarak alamaz<sup>20</sup>. Bu, modern radyoloji uygulamalarında büyük bir engel gibi görünebilir; zira radyoloji verisi yoğun olarak görsel (MRI, CT, X-ray) ve giderek artan şekilde metinsel (yapılandırılmış raporlar) formdadır. Bu nedenle BN kullanmak isteyen bir uygulama, mutlaka bir ön işleme (özellik çıkarımı) aşaması gerektirir. Örneğin bir CNN modeli önce görüntüde tümörü saplayacak, özelliklerini (boyut, intensite, konum vb.) çıkartacak ki Bayesien ağa beslenebilisin<sup>54</sup> <sup>70</sup>. Bu ek adım, sistemin karmaşıklığını artırır ve BN'nin tek başına çalışmasını sınırlayan bir faktördür.
- **Sürekli Değişkenlerin Diskretizasyon Zorunluluğu:** Yukarıda da bahsedildiği gibi BN'ler çoğunlukla kategorik verilerle çalışır. Sürekli değerlerin (ör. yaş, tümör çapı, kan değeri) uygun aralıklara bölünmesi gerekliliği teknik bir zorluktur<sup>20</sup> <sup>40</sup>. Yanlış veya kötü seçilen aralıklar model performansını düşürebilir; ayrıca çok fazla aralık tanımlamak parametre sayısını patlatıp daha fazla veri ihtiyacı doğurur. Makalede, BN'lerin sürekli değişkenler için doğrudan sadece **koşullu Gaussian** dağılımını desteklediği belirtilmiş, bunun dışındaki durumlarda diskretizasyonun şart olduğu vurgulanmıştır<sup>20</sup> <sup>40</sup>. Otomatik diskretizasyon algoritmaları (örn. değere göre binning, karar ağaçları ile sınır belirleme) olsa da, bunlar da ayrı bir optimizasyon problemidir.
- **Sınırlı Kullanım Alanı ve Yaygınlık:** Bir diğer önemli sınırlama, Bayesien ağların sağlık uygulamalarında **henüz dar bir alanda kalmış olmasıdır**. Makalede atif yapılan bir derlemeye göre, yayımlanmış BN çalışmalarının %60'ı sadece kalp hastalıkları, kanser, psikiyatrik bozukluklar ve akciğer hastalıkları gibi dört ana başlıkta toplanmıştır<sup>71</sup>. Yani diğer alanlarda (örneğin enfeksiyon hastalıkları, ortopedik durumlar, vb.) BN kullanımı seyrek. Dahası, yüzlerce akademik makaleye rağmen **rutin klinik pratiğe geçen BN tabanlı sistem sayısı yok denecek kadar azdır**<sup>72</sup>. Bu “uygulama boşluğu”, teknolojinin var olduğu ancak günlük hasta bakımında somut olarak kullanılmadığı anlamına gelir. Nedenleri arasında, klinisyenlerin bu modellere aşinalığının az olması, hastane sistemlerine entegrasyon güçlüğü, veya mevcut iş akışını çok değiştirmesi olabilir. Sonuç olarak BN'lerin **gerçek dünyada kanıtlanmış yararları** henüz sınırlıdır, daha yaygın benimsenmesi için çaba gerekmektedir.
- **Model Kurulumunun ve Bakımının Zorluğu:** Makalede doğrudan degenilmese de BN'lerin pratikteki bir sınırlaması, **modeli oluşturmak için gereken uzmanlık ve emek** olabilir. Derin öğrenme modelleri büyük verilerle kendini eğitirken, BN'lerde genelde uzman katkısı (değişken ilişkilerinin belirlenmesi, olasılıkların ayarlanması) gereklidir. Özellikle karmaşık bir BN modeli oluşturmak, hem istatistik hem tıp bilgisini bir arada gerektirir. Ayrıca model kurulduktan sonra

güncel tıbbi bilgilere göre bakımının yapılması (olasılık değerlerini yeni yayılara göre güncelleme gibi) insan müdahalesi gerektirebilir. Bu faktörler, BN'lerin klinik ortamındaki yayılmasını yavaşlatan pratik sınırlamalarıdır.

- **Hesaplama Karmaşıklığı:** Bayesien ağlarda **çıkarım (inference)** işlemi, ağın büyülüğüne (düğüm ve kenar sayısına) bağlı olarak hesaplama açısından karmaşık hale gelebilir. Teorik olarak, BN'lerde kesin çıkarım NP-zor bir problemdir. Makale, günümüzde **yüzlerce değişkenli ağlarda bile verimli çıkışım algoritmaları** bulunduğuunu belirtse de <sup>73</sup> <sup>74</sup>, çok büyük ağlar için performans sorunu ortaya çıkabilir. Örneğin binlerce değişkenli bir BN'de gerçek zamanlı hesaplama mümkün olmayabilir veya yaklaşık yöntemler kullanmak gerekebilir. Bu da modelin ölçeklenebilirliğini sınırlayan bir etkendir.

**Önyargı Riskleri:** Makalede doğrudan "algorithmic bias" yani veriden kaynaklı önyargı konusuna değinilmemiştir. Ancak bu konu, tüm yapay zekâ uygulamalarında olduğu gibi Bayesien ağlar için de önem taşır. BN'ler temelde olasılıkları ya **veriden öğrenir** ya da **uzmanlardan alır**. Eğer kullanılan veri demografik veya kurumsal bir önyargı içeriyorsa, modelin çıktıları da bunu yansıtacaktır. Örneğin, eğitim verisindeki hastalar ağırlıklı olarak belirli bir etnik gruptan ise, model diğer gruplarda farklı prevalans gösteren hastalıkları doğru yansıtamayabilir. Benzer şekilde, bir uzmanın subjektif kanaatleriyle doldurduğu olasılık tabloları da o uzmanın bilinçli/bilinsiz önyargılarını barındırabilir. Bu nedenle, BN kurulurken **veri ve bilgi kaynağının temsil gücü** kritik önem taşır. Bir avantaj olarak, BN'lerin **şeffaf yapısı**, önyargı riskini tespit etmeyi kolaylaştırabilir: Modelin hangi durumda ne sonuç verdiği ve neden o sonuca varlığı incelenerek, bariz bir dengesizlik veya tutarsızlık fark edilirse düzeltilebilir. Örneğin bir cinsiyet değişkeninin haksız yere sonucu etkilediği görülürse, modelin o kısmı revize edilebilir. Derin öğrenmeye kıyasla BN'lerde bu tür müdahaleler yapmak mümkündür (çünkü parametreler tablolar halinde anlaşılabılır formdadır) <sup>75</sup> <sup>76</sup>. Bununla birlikte, **ön yargıların bizzat tip literatüründe yerleşik olabileceği** gerçeği de unutulmamalıdır; BN literatürüne dayanarak kuruluyorsa, literatürde az temsil edilen gruplar veya atlanmış riskler modele yansımayabilir.

**Etik Değerlendirmeler:** Bayesien ağların klinik kullanımında etik konular, genel AI uygulamalarındaki etik konularla paraleldir. En önemli noktalardan biri **hesap verilebilirlik ve şeffaflıktır**. Bu bağlamda BN'ler aslında olumlu bir profil çizer: Karar süreçlerini açıklayabildikleri için, bir hastaya veya meslektaş'a modelin önerdiği tanının gerekçesi gösterilebilir <sup>77</sup> <sup>78</sup>. Örneğin, model "hastanın yaşı ileri ve şu şu bulguları mevcut olduğu için, Bayes kuralına göre hastalık X'in olasılığı yükseldi" diyebilir. Bu, etik açıdan AI'nın kara kutu olmasından kaynaklanan güven sorununu azaltır. Doktorlar, modelin tavsiyesini körü körüne değil, mantığını görerek kullanabilirler. Yine de, etik olarak **son kararın sorumluluğu** insanda olmalıdır: BN gibi bir sistem karar desteği verirken, hekimin bunu bir araç olarak kullanıp kendi klinik yargısını da katması beklenir. Model yanılabilir veya tüm bilgiyi bilemeyecek; hekim modelin önerisine katılmayabilir. Bu denge, tıbbi yapay zekâ etiğinin temel prensiplerinden biridir.

Bir diğer etik boyut, **hastaların verilerinin kullanımı ve gizliliğidir**. BN modelleri eğitilirken hasta verileri kullanılmışsa, bu verilerin anonimliğinin korunması gereklidir. Makalede bu konuya girilmese de, AI modelleri geliştirilirken HIPAA gibi yasal düzenlemelere uyulması ve hasta mahremiyetinin gözetilmesi gerektiği açıklıdır. Ayrıca BN modelleri, eğer sürekli öğrenme modunda çalışır ve sağlık sistemi verilerini zamanla toplarsa, bu da güvenlik ve gizlilik adına dikkatle yönetilmelidir (kimin verisi modele giriyor, nasıl saklanıyor, vs.).

Son olarak, **klinik sorumluluk ve yasal konular** da etik tartışmaların parçasıdır. Bayesien ağlar bir tanı önerdiğinde ve hekim buna güvenirse, yanlış tanı durumunda sorumluluk paylaşımı nasıl olacak? Bu henüz geniş ölçekte test edilmediği için net değildir. Ancak BN'lerin açıklanabilir olması, hukuki olarak da avantaj sağlayabilir; en azından "makine böyle söyledi, nedenini bilmiyoruz" denmeyecek, modelin mantığı izah edilebilecektir. Bu da sorumluluk analizinde yardımcı olabilir.

## Sonuç ve Genel Değerlendirme

Makalenin ortaya koyduğu üzere, **Bayesien ağlar** radyolojide yapay zekâ uygulamaları içinde kendine özgü ve **değerli bir yer** tutmaktadır. Derin öğrenmenin hakim olduğu bir dönemde, Bayesien ağlar **küçük veri ile öğrenebilme, çok kaynaklı bilgiyi birleştirme ve çıkarım sürecini açıklayabilme** gibi özellikleriyle öne çıkıyor <sup>57 79</sup>. Mühendislik perspektifinden, BN'ler zengin bir olasılıksal çerçeveye sunup farklı AI teknikleriyle entegre edilebilen esnek araçlar. Tıp perspektifinden bakıldığından ise, doktorların karar verme süreçlerini destekleyen, onların düşünce tarzına yakın (nedensel ve olasılıksal akıl yürütme şeklinde) ve sonuçları anlaşılabilir sistemler.

Makale, Bayesien ağların halihazırda abdominal radyoloji, muskuloskeletal radyoloji, meme görüntüleme, nöroradyoloji gibi alanlarda başarılı örneklerinin bulunduğu, ancak klinik rutine geçişin sınırlı kaldığını aktarıyor <sup>71</sup>. Gelecekte en büyük fırsat, BN'lerin **derin öğrenme ile hibrit kullanımı** gibi görünüyor: Bu sayede hem görüntülerden otomatik veri çıkarma hem de bu verileri klinik bağlamda yorumlama bir arada mümkün olabilecek <sup>59 22</sup>. Böyle yaklaşımlar, bir anlamda **radyologun çalışma şeklini taklit eden** (bulguları algılama + sentezleme) ve insan uzman düzeyinde performansa ulaşan sistemler yaratır ki ilk sonuçlar umut vericidir <sup>23</sup>.

Sonuç olarak, "Bayesian Networks in Radiology" makalesi bizlere şunu göstermektedir: **Yapay zekâ, sadece derin öğrenmeden ibaret değildir**. Bayesien ağlar gibi yöntemler, farklı problemlere yönelik farklı araçlar olarak, tıpta yapay zekâ portföyümüzü zenginleştirmektedir. Doğru problemde doğru yöntem kullanıldığında (örneğin az veriyle karşılaşılan ve açıklama gerektiren tanı sorularında BN'ler gibi), hem mühendislik hem de klinik açıdan optimal sonuçlar elde etmek mümkün olacaktır. Bu makalenin işliğinde, geleceğin radyoloji AI sistemlerinin **açıklanabilir, güvenilir ve entegre** karar destek araçları olacağı öngörlülebilir. Bayesien ağlar da bu gelecekte önemli bir rol oynamaya adaydır <sup>80 81</sup>.

**Kaynaklar:** Makaledeki bilgiler, RSNA'nın *Radiology: Artificial Intelligence* dergisinde yayımlanan Shawn X. Ma ve arkadaşlarının "Bayesian Networks in Radiology" başlıklı derlemesinden alınmıştır. Tüm özel bilgi ve alıntılar ilgili kaynak satır numaralarıyla birlikte belirtilmiştir. Bu derinlemesine analiz, makalenin teknik içeriğini ve klinik yansımalarını kapsamlı biçimde özetlemeyi amaçlamıştır. <sup>9 57</sup>, <sup>8 33</sup>, <sup>42 25</sup> gibi atıflar, doğrudan makaleden alınan kritik vurguları desteklemektedir. Makalenin kendisi ve referansları, Bayesien ağların tıbbi yapay zekâ alanındaki konumunu daha ayrıntılı incelemek isteyenler için değerli bir kaynak oluşturmaktadır.

- 
- 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25 26 27 28 29  
30 31 32 33 34 35 36 37 38 39 40 41 42 43 44 45 46 47 48 49 50 51 52 53 54 55 56 57 58  
59 60 61 62 63 64 65 66 67 68 69 70 71 72 73 74 75 76 77 78 79 80 81 Bayesian Networks in  
Radiology - PMC

<https://pmc.ncbi.nlm.nih.gov/articles/PMC10698603/>